队伍编号	MC2607188
题号	C

中老年人群高血脂症的风险预警及干预方案优化

摘 要

针对中老年人群高血脂症的早期筛查、分层预警与个体化干预需求，本文基于附件1000例样本数据，构建了“指标筛选—风险预警—干预优化”的一体化分析框架.

针对问题一，在处理完标签异常后，本文采用多种统计手段评估指标与痰湿程度、确诊风险的关联. 通过Spearman相关系数、互信息及随机森林特征重要度等多维方法的等权综合评价，发现TG、TC、LDL-C和HDL-C是最具解释力的高血脂诊断指标. 此外，在剔除这些直接诊断性指标后，血尿酸、空腹血糖、BMI、活动能力及痰湿积分仍体现出较强的先兆预警价值.

针对问题二，本文将风险识别细分为“诊断”与“早预警”两个层面. 通过对数据进行分位截尾、特征派生等稳健预处理，诊断型模型（保留核心脂质变量）在测试集上达到了1.0000的AUC；而剔除直接血脂指标的早预警模型也取得了0.8283的AUC. 结合模型概率、临床指标和功能现状，本文划定了低、中、高三级风险阈值，并挖掘出诸如“血脂异常 + 尿酸偏高”等核心高发组合特征，为临床评估提供了可参考的规则依据.

针对问题三，本文构建了以月度干预强度及每周训练频次为决策变量的离散动态规划干预模型，力求在2000元总预算内使得痰湿患者的体质积分降低至少10%. 模型综合考量了年龄与活动能力的限制，对1、2、3号患者生成了“前期集中发力降分，后期低成本维持”的个体化最优方案. 整体研究不仅保证了模型的精准性与稳健性，亦突出了基层慢病管理的可操作性与现实指导意义.

关键词：高血脂症，痰湿体质，风险预警，随机森林，干预优化

目录

一、 问题重述 1
二、 数据理解与总体思路 1
2.1 数据核验与预处理 1
三、 模型假设 4
四、 符号说明 4
五、 问题一：关键指标筛选与体质贡献分析 4
5.1 双目标筛选思路与评价指标 4
5.2 关键指标筛选结果及解释 6
5.3 九种体质的风险贡献差异 8
六、 问题二：多维风险预警模型的构建 10
6.1 双层风险预警框架 10
6.2 三级风险阈值设计 15
6.3 高风险核心特征组合识别 17
七、 问题三：痰湿体质患者的六个月干预优化 19
7.1 决策变量与约束条件 19
7.2 样本 1、2、3 的最优方案 20
7.3 患者特征与最优方案的匹配规律 21
八、 模型检验与结果讨论 22
九、 模型评价 24
9.1 模型优点 24
9.2 模型不足 24
参考文献 24
附录 1： 算法实现说明 25
附录 2： 问题三核心求解伪代码 25

一、问题重述

高血脂症是中老年群体中最常见的慢性代谢性疾病之一，既与常规血脂指标直接相关，又与中医体质偏颇、活动能力下降、生活方式不良等因素存在显著耦合．题目给出了九种体质标签及积分、ADL/IADL 活动能力评分、血脂与代谢指标、生活习惯信息以及高血脂确诊标签，要求完成三个层面的任务：

1. 从血常规体检指标和活动能力指标中筛选既能表征痰湿体质严重程度、又能预警高血脂风险的关键指标，并研究九种体质对高血脂风险的贡献差异．
2. 构建融合多维特征的三级风险预警模型，给出低、中、高风险的阈值划分依据，并识别痰湿体质高风险人群的核心特征组合．
3. 对体质标签为 5 的痰湿体质患者设计六个月干预方案，在满足年龄、活动能力和预算约束的情况下，以较低成本实现痰湿积分下降目标，并给出样本 ID 为 $1, 2, 3$ 的最优方案．

二、数据理解与总体思路

附件数据共包含 1000 例样本、37 个字段，无缺失值；其中高血脂确诊样本 793 例，未确诊样本 207 例．将主导体质标签按九种体质积分最大项修正后，痰湿体质样本数最多，共 292 例．整体来看，数据具有两个鲜明特征：其一，血脂指标与确诊标签高度同源，若直接用于分类，会得到非常高的判别精度；其二，活动能力、代谢异常与体质积分在排除直接血脂指标后，仍具有提前预警价值．因此本文采用图 1 所示的双层建模思路：

1. 问题一侧重“筛指标”和“看差异”，从统计相关性、信息量和树模型重要度三个角度联合打分；
2. 问题二将风险识别划分为“诊断型识别”和“早预警识别”，前者追求精度，后者强调前瞻性与可解释阈值；
3. 问题三把中医调理等级视为随痰湿积分动态变化的基础成本，把活动干预强度和频次作为优化变量，建立约束优化模型．

2.1 数据核验与预处理

本文在建模前加入了结构核验与稳健预处理两层步骤．

首先，对原始字段进行一致性检查．结果表明：ADL 五个子题项之和与 ADL 总分完全一致，IADL 五个子题项之和与 IADL 总分完全一致，且 ADL 总分与 IADL 总分之和与活动量表总分完全一致；高血脂二分类标签为 0 时，分型标签均为 0，说明标签系统内部协调．但同时发现，原始主导体质标签与九种体质积分最大项并不总是完全一致，

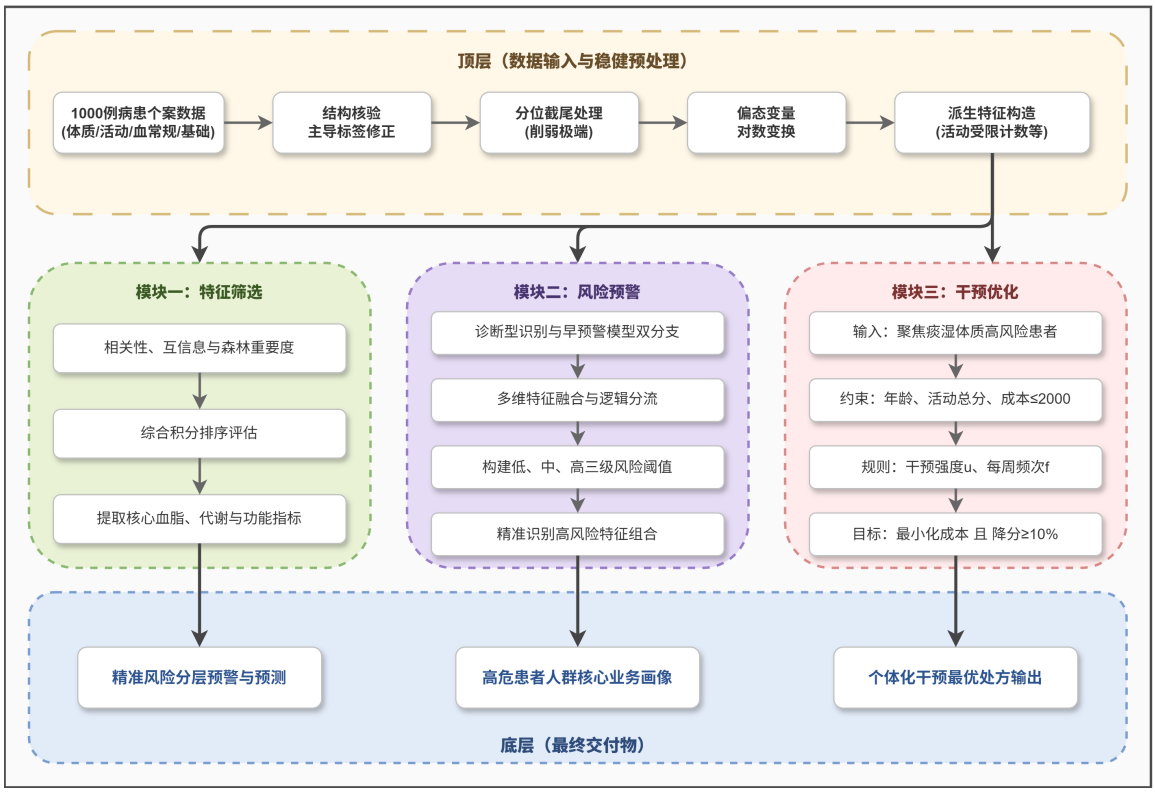

图 1 本文的总体建模流程

样例中共有 65 例样本存在不一致现象．考虑到题目中的“主导体质标签”本应表示九种体质中的主导类型，本文将这 65 例视为标签异常，并统一按九种体质积分最大项对主导体质标签进行修正；其余 935 例样本原标签与积分最大项一致．

其次，对进入问题二风险模型的连续变量实施稳健化处理．考虑到 TG、血尿酸、BMI 等变量存在偏态与极端值扰动，本文仅在训练集上估计 1% 与 99% 分位点，并据此对 HDL-C、LDL-C、TG、TC、空腹血糖、血尿酸和 BMI 进行分位截尾，再将同样的阈值应用于测试集，以避免数据泄漏．设连续变量 x 在训练集上的 1% 与 99% 分位点分别为 $q_{0.01}(x)$ 与 $q_{0.99}(x)$，则其稳健化后的截尾变量定义为

$$x_i^{(w)} = \min\left\{\max\left(x_i, q_{0.01}(x)\right), q_{0.99}(x)\right\}. \tag{1}$$

在此基础上，对右偏更明显的 TG 和血尿酸进一步做对数变换：

$$\mathrm{TG}_i^{(\log)} = \log\left(1 + \mathrm{TG}_i^{(w)}\right), \qquad \mathrm{UA}_i^{(\log)} = \log\left(1 + \mathrm{UA}_i^{(w)}\right). \tag{2}$$

以 TG 为例，图 2 给出了稳健预处理前后的分布对比．可以看到，原始 TG 数据呈现明显的右偏态与长尾极端值；在训练集 1% 分位截尾与 $\log(1+x)$ 变换后，分布主体更加集中，尾部被明显压缩，从而更适合进入后续随机森林模型进行稳定学习．

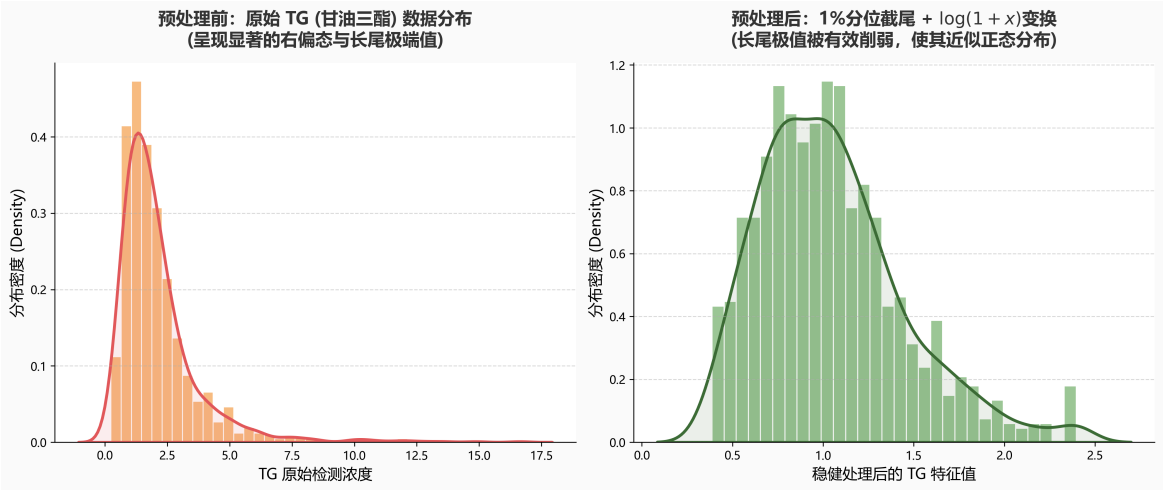

图 2 TG 在稳健预处理前后的分布对比

同时构造 non-HDL-C 这一脂质结构变量：

$$\mathrm{nonHDL}_i = \mathrm{TC}_i^{(w)} - \mathrm{HDL}_i^{(w)}. \tag{3}$$

考虑到 non-HDL-C 与 TC、HDL-C 存在线性确定关系，若再同时引入 TC/HDL-C、LDL-C/HDL-C、TG/HDL-C 等派生比值，会放大同一脂质家族的重复表达，引起多重共线性问题．因此，本文在诊断型模型中仅保留 non-HDL-C、TG 和 LDL-C 这一组脂质组合，用 non-HDL-C 概括总胆固醇与保护性胆固醇的净失衡程度，用 TG 表征甘油三酯异常，用 LDL-C 表征低密度脂蛋白负担，从而兼顾医学解释性与变量独立性．

最后，针对活动能力和体质信息加入结构化派生变量．活动变量中，由于 ADL/IADL 子题项与总分之间存在严格加总关系，本文在问题二模型中不再同时放入全部子题项与总分，而是保留 ADL 总分、IADL 总分，并额外构造“活动受限题项数”以补充局部功能损伤信息．设 10 个 ADL/IADL 子题项记为 a_{ij}，经验阈值取 $\tau = 8$，则第 i 个样本的活动受限计数定义为

$$C_i^{(\mathrm{act})} = \sum_{j=1}^{10} \mathbb{I}(a_{ij} < \tau), \tag{4}$$

其中 $\mathbb{I}(\cdot)$ 为指示函数．该变量反映的是“低分题项有多少个”，因此它补充的是总分无法直接表达的受限范围信息．

体质变量中，设第 i 个样本的九种体质积分排序后最大值与次大值分别为 $s_{i(1)}$ 和 $s_{i(2)}$，则进一步构造

$$S_i^{(\max)} = s_{i(1)}, \qquad M_i^{(\mathrm{gap})} = s_{i(1)} - s_{i(2)}, \tag{5}$$

分别表示“最强体质倾向的绝对强度”和“第一体质与第二体质之间的优势差距”．由于主导体质标签已在数据核验阶段按积分最大项完成修正，后续建模不再单独构造标签一致性标记．这样处理后，既保留了医学解释性，又降低了冗余表达和极端值对随机森林训练的干扰．需要说明的是，问题一的排序对象仍保持为原始血常规和活动量表指标，上述稳健化步骤主要用于问题二的预测模型与风险分层．

三、模型假设

1. 附件样本已完成临床检验与标签标注，数据可直接用于建模与验证.
2. 题目给出的临床正常值区间与活动能力约束规则具有统一适用性，视为风险分层与干预求解的硬约束.
3. 痰湿积分每月变化主要由活动干预强度与频次驱动；中医调理等级在题目中未给出显式降分系数，因此本文将其视为按积分区间自动匹配的基础调理成本.
4. 在相同活动干预强度下，若每周训练频次低于 5 次，则痰湿积分近似保持稳定；若每周训练频次不低于 5 次，则按题目给出的比例规则递推下降.
5. 六个月周期内患者的年龄组、性别以及吸烟饮酒史不发生变化，活动量表初值用于确定可选强度上界.

四、符号说明

符号	含义
x_{ij}	第 i 个样本在第 j 个候选指标上的观测值
P_i	第 i 个样本的痰湿积分
y_i	第 i 个样本的高血脂二分类标签
S_j	第 j 个候选指标的综合筛选得分
L_k	第 k 类主导体质对应的风险提升度
$\hat{p}_i$	风险预警模型对样本 i 输出的高血脂风险概率
R_i	样本 i 的三级风险等级
u	活动干预强度等级，$u \in \{1,2,3\}$
f	每周训练频次，$f \in \{1,2,\ldots,10\}$
s_m	第 m 个月末的痰湿积分
$r(u,f)$	在强度 u、频次 f 下的月度痰湿降幅比例
C	六个月总干预成本

五、问题一：关键指标筛选与体质贡献分析

5.1 双目标筛选思路与评价指标

问题一并不是单纯寻找“与痰湿积分最相关”的变量，而是要从血常规体检指标和活动量表评分中筛出一组既能刻画痰湿偏颇程度、又能预警高血脂发病风险的关键指标．因此，本文将其视为一个双目标筛选问题．需要首先说明的是，活动能力变量之间存在明显的结构性共线性：ADL 总分是 5 个 ADL 子题项之和，IADL 总分是 5 个 IADL 子题项之和，而活动量表总分又等于 ADL 总分与 IADL 总分之和．若将总分、整体总分和全部子题项同时放入同一候选池，会导致功能能力维度被重复计分．因此，本文采

用分层处理策略：主分析只保留 ADL 总分和 IADL 总分；活动量表总分作为后续问题二风险分层和问题三强度约束的派生变量，不参与问题一主排序．同时，为了检验是否存在某个子题项能够明显优于总分变量，补充分析中再将 10 个 ADL/IADL 子题项与 HDL-C、LDL-C、TG、TC、空腹血糖、血尿酸、BMI 一并放入同一候选池重新排序．基于这一处理，主分析的候选变量集合记为

$$X = \{\text{ADL 总分、IADL 总分、HDL-C、LDL-C、TG、TC,}\\ \text{空腹血糖、血尿酸、BMI}\}. \tag{6}$$

其中每个候选变量记为 x_j，痰湿积分记为 P，高血脂二分类标签记为 y．对每个候选变量，本文从“单变量相关性”“非线性信息量”和“多变量联合重要度”三个角度进行评价．

首先，为了衡量候选指标对痰湿积分的单调关联程度，计算 Spearman 秩相关系数，并取其绝对值

$$R_j = \left|\rho_s(x_j, P)\right|. \tag{7}$$

这里取绝对值，是因为问题一关心的是“关联强弱”而非“正负方向”．例如 HDL-C 或活动量表总分可能与痰湿积分呈负相关，但这类负向指标同样具有很强的风险识别意义，不能因为方向为负就被排除．

其次，为了避免仅依赖线性或单调关系，进一步计算互信息指标：

$$M_j^{(1)} = I(x_j; P), \qquad M_j^{(2)} = I(x_j; y), \tag{8}$$

其中 $M_j^{(1)}$ 衡量指标对痰湿积分的非线性解释能力，$M_j^{(2)}$ 衡量指标对高血脂标签的非线性预警能力．

再次，为了考察变量之间交互作用下的多变量联合贡献，分别建立随机森林回归模型和随机森林分类模型：

$$P = f_{\text{RF-reg}}(X), \qquad y = f_{\text{RF-clf}}(X), \tag{9}$$

并提取各候选变量在两类模型中的重要度，记为

$$F_j^{(1)}, \qquad F_j^{(2)}. \tag{10}$$

综上，每个候选指标共得到五类评价量：

$$R_j, \quad M_j^{(1)}, \quad M_j^{(2)}, \quad F_j^{(1)}, \quad F_j^{(2)}. \tag{11}$$

由于这五类统计量量纲不同，且其中有的反映相关强度、有的反映信息量、有的反映树模型重要度，本文不直接对原值加权，而是先分别排序，再进行积分汇总．设共有 q 个候选指标，若第 j 个指标在第 m 类评价下的名次为 $\text{rank}_j^{(m)}$，则定义其名次得分为

$$s_j^{(m)} = q - \text{rank}_j^{(m)} + 1. \tag{12}$$

最终综合筛选得分定义为

$$S_j = \sum_{m=1}^{5} s_j^{(m)}. \tag{13}$$

本文主分析共有 $q = 9$ 个候选指标，因此在某一评价维度下排名第 1、2、9 位的指标，分别得到 9、8、1 分．S_j 越大，说明该指标在五种评价视角下越稳定地靠前，也就越适合同时承担“体质刻画”和“风险预警”两类任务．这种“排序积分”的处理方式比直接对原值做线性加权更稳健，也更符合程序实现．

5.2 关键指标筛选结果及解释

基于上述流程，主分析中 9 个候选指标的综合排序结果依次为 TC、TG、BMI、HDL-C、ADL 总分、LDL-C、空腹血糖、IADL 总分和血尿酸．换言之，本文不是直接“把这些指标列出来”，而是先让每个指标分别在五个维度上独立排序，再看其总积分是否持续靠前．例如，TC 在五类评价中的名次分别为 $2, 7, 3, 4, 1$，因此综合得分为

$$S_{\mathrm{TC}} = (9-2+1) + (9-7+1) + (9-3+1) + (9-4+1) + (9-1+1) = 33. \tag{14}$$

同理，ADL 总分在五类评价中的名次分别为 $1, 2, 7, 8, 9$，因此综合得分为 23．这说明 TC、TG 等直接血脂指标在高血脂分类任务上极强，因此排在前列；而 ADL 总分虽然对高血脂标签的单项判别力不如血脂指标，但它在痰湿积分相关性和回归解释能力上持续靠前，因此仍被保留为核心功能指标．

表 1 问题一主分析 9 个候选指标在五类评价下的名次与综合得分

指标	Spearman	MI-回归	MI-分类	RF-回归	RF-分类	综合得分
TC	2	7	3	4	1	33
TG	6	6	1	5	2	30
BMI	3	1	9	1	7	29
HDL-C	7	5	4	3	5	26
ADL 总分	1	2	7	8	9	23
LDL-C	8	4	5	6	4	23
空腹血糖	5	8	8	2	6	21
IADL 总分	4	3	6	9	8	20
血尿酸	9	9	2	7	3	20

表 1 说明，在处理了活动能力维度的结构性共线性之后，问题一主分析的排序结果更加集中于九个无重复候选变量．直接血脂指标在高血脂分类任务上占据优势，因此 TC、TG、HDL-C、LDL-C 稳定居前；BMI、空腹血糖和血尿酸则体现出代谢协同作用；ADL 总分和 IADL 总分说明总体功能状态仍然能够提供对痰湿偏颇和风险水平的联合信息．

作为补充分析，本文又构造了一个“子题项替代总分”的混合候选池：用 10 个 ADL/IADL 子题项替代 ADL 总分与 IADL 总分，并与 HDL-C、LDL-C、TG、TC、空腹血糖、血尿酸、BMI 一起重新进行五维排序．结果表明，在这一混合池中，排序靠前的指标依次为 TC、TG、ADL 吃饭、BMI、HDL-C、ADL 用厕、LDL-C、血尿酸、IADL 理财和 ADL 洗澡．其中，ADL 吃饭和 ADL 用厕确实表现出较强信号，说明某些基础生活自理条目能够比总分更敏锐地刻画痰湿偏颇与代谢风险．

表 2 问题一补充分析中混合候选池的前十指标

指标	Spearman	MI-回归	MI-分类	RF-回归	RF-分类	综合得分
TC	3	15	3	4	2	63
TG	10	14	1	3	1	61
ADL 吃饭	1	6	8	8	8	59
BMI	7	1	17	1	6	58
HDL-C	11	13	4	5	5	52
ADL 用厕	2	7	7	9	16	49
LDL-C	13	12	5	7	4	49
血尿酸	14	17	2	6	3	48
IADL 理财	5	2	11	10	14	48
ADL 洗澡	4	4	14	11	13	44

表 2 说明，子题项层面确实存在表现突出的变量，尤其是 ADL 吃饭和 ADL 用厕；这意味着如果研究重点偏向“解释具体行为功能与痰湿偏颇的关系”，完全可以采用子题项层分析口径．然而，从本题整体求解链条看，问题二中的风险阈值与问题三中的活动强度约束都直接依赖总分变量，而混合候选池中也未出现多个子题项在各维度上同时全面压制血脂和代谢指标的情况，因此本文最终仍保留“总分层做主分析，子题项层做补充分析”的结构．

需要强调的是，问题一中的“筛选”对象仅限于血常规与活动量表变量，九种体质积分并不属于这一筛选集合，而是用于后续的体质贡献差异分析．因此，这里不把九类体质积分与筛选结果混在同一张表中．综合医学解释性、统计稳定性和后续建模可用性，本文将主分析中排序靠前的指标整理为三类建模关键变量，而活动量表总分则作为由 ADL 总分与 IADL 总分导出的派生变量，在问题二和问题三中继续使用：

1. 直接血脂指标：TG、TC、LDL-C、HDL-C，决定了当前是否已表现出明确的血脂异常；

2. 代谢协同指标：血尿酸、空腹血糖、BMI，反映代谢紊乱程度和生活方式风险；

3. 功能能力指标：ADL 总分、IADL 总分，反映身体耐受度和日常活动水平．

表 3 用于后续建模的关键指标及作用解释

类别	指标	主要作用
血脂类	TG、TC、LDL-C、HDL-C	直接决定当前是否存在血脂异常，是诊断型风险识别的核心变量
代谢类	血尿酸、空腹血糖、BMI	与脂质代谢紊乱、肥胖及胰岛素抵抗存在协同关系，适合用于早预警
功能类	ADL 总分、IADL 总分	作为主分析中的功能变量，刻画身体活动能力与耐受度，并对痰湿改善具有外在解释力
派生变量	活动量表总分	由 ADL 总分与 IADL 总分相加得到，主要用于问题二风险阈值与问题三强度约束

5.3 九种体质的风险贡献差异

本文采用“描述性风险提升度 + 模型化边际贡献”两层口径刻画九种体质的风险差异．首先，以主导体质标签为分组变量，定义第 k 类体质的风险提升度为

$$L_k = \frac{p_k}{p}, \tag{15}$$

其中 p_k 为主导体质标签为 k 的样本确诊率，p 为总体确诊率．若 $L_k > 1$，则说明该主导体质组的发病风险高于样本总体平均水平．该指标直观反映了不同主导体质组之间的组间差异，但它只使用了离散标签信息，无法反映同一样本同时具有多种体质偏颇的情形，也未控制年龄、性别、吸烟和饮酒等基础差异，因此更适合作为描述性统计而非最终的“贡献度”定义．

表 4 九种主导体质的确诊率与风险提升度

体质标签	样本量	确诊率	风险提升度
平和质	190	0.811	1.022
气虚质	90	0.800	1.009
阳虚质	75	0.827	1.042
阴虚质	80	0.787	0.993
痰湿质	292	0.781	0.985
湿热质	79	0.797	1.006
血瘀质	75	0.733	0.925
气郁质	66	0.788	0.994
特禀质	53	0.830	1.047

进一步地，记第 i 个样本第 k 类体质积分为 x_{ik}，其标准化变量定义为

$$z_{ik} = \frac{x_{ik} - \mu_k}{\sigma_k}, \tag{16}$$

其中 μ_k 与 σ_k 分别为第 k 类体质积分的样本均值和标准差．令 W_i 表示由年龄组、性别、吸烟和饮酒构成的基础控制变量向量，建立标准化逻辑回归模型

$$\Pr(Y_i = 1) = \frac{1}{1 + \exp\left[-\left(\beta_0 + \sum_{k=1}^{9} \beta_k z_{ik} + \gamma^\top W_i\right)\right]}, \tag{17}$$

其中 Y_i 表示样本 i 是否患高血脂．此处不再将 TC、TG、LDL-C、HDL-C 等直接诊断变量加入模型，是为了避免强同源血脂指标掩盖体质积分本身的边际作用．需要强调的是，逻辑回归中的系数 β_k 作用在对数几率上，而不是直接作用在发病概率上，因此不能把 β_k 直接解释为“概率增加了多少”．

设模型对样本 i 的预测概率为 $\hat{p}_i$，则第 k 类体质积分对该样本发病概率的局部影响为

$$\frac{\partial \Pr(Y_i = 1)}{\partial z_{ik}} = \hat{p}_i(1 - \hat{p}_i)\beta_k. \tag{18}$$

它表示：在其他变量保持不变时，第 k 类体质积分每增加 1 个标准差，样本 i 的高血脂预测概率会发生多大变化．由于不同样本的基线风险不同，这个变化量并不相同，因此需要对全体样本取平均．于是定义第 k 类体质的平均边际效应为

$$C_k = \frac{1}{n} \sum_{i=1}^{n} \hat{p}_i(1 - \hat{p}_i)\beta_k. \tag{19}$$

因此，C_k 可以理解为“第 k 类体质积分每增加 1 个标准差时，高血脂发病概率在全体样本上的平均变化量”．其符号表示影响方向：$C_k > 0$ 说明该体质积分升高会提高发病概率，$C_k < 0$ 说明其升高与发病概率下降相关；其绝对值越大，说明这种体质对概率的平均扰动越强．进一步定义贡献占比

$$G_k = \frac{|C_k|}{\sum_{j=1}^{9} |C_j|}, \tag{20}$$

则 G_k 可以理解为九种体质在模型意义下对总体风险影响强度的相对份额．换言之，AME 先把逻辑回归系数从“对数几率尺度”转换为“概率尺度”，再通过归一化得到可直接比较的贡献占比．

样例数据表明，两层口径得到的结论并不完全一致．若仅按修正后的主导体质标签分组，特禀质的风险提升度最高，为 1.047，血瘀质最低，为 0.925，说明九种主导体质在组间发病率上确有高低差异，但整体差距并不悬殊．若转入模型化定义并控制基础信息，则气虚质的平均边际效应最大，贡献占比为 0.312；平和质次之，贡献占比为 0.229；湿热质和血瘀质的边际效应为负，说明在控制其他条件后，其积分升高与发病概率下降相关．由此可见，主导体质标签的组间确诊率更接近“群体画像”，而标准化逻辑回归的平均边际效应更接近“体质积分本身的边际风险贡献”．在后续风险预警中，本文以后者作为体质贡献差异的主定义，以前者作为辅助描述．

表 5 九种体质的模型化边际贡献（标准化逻辑回归 + AME）

体质类型	标准化系数	平均边际效应	贡献占比
气虚质	0.119	0.0193	0.312
平和质	0.087	0.0142	0.229
湿热质	-0.057	-0.0092	0.149
血瘀质	-0.057	-0.0092	0.149
特禀质	-0.023	-0.0037	0.060
阳虚质	0.019	0.0031	0.050
气郁质	0.018	0.0029	0.047
阴虚质	-0.001	-0.0002	0.004
痰湿质	0.000	0.0000	0.000

为便于直观比较各体质对发病概率的正负向扰动方向，图 3 给出了九种体质 AME 与贡献占比的可视化结果．图中横向位置表示 AME 的正负与大小，括号中的百分比表示该体质在总体绝对边际效应中的贡献占比，因此该图与表 5 共同刻画了各体质在模型意义下的风险贡献结构．

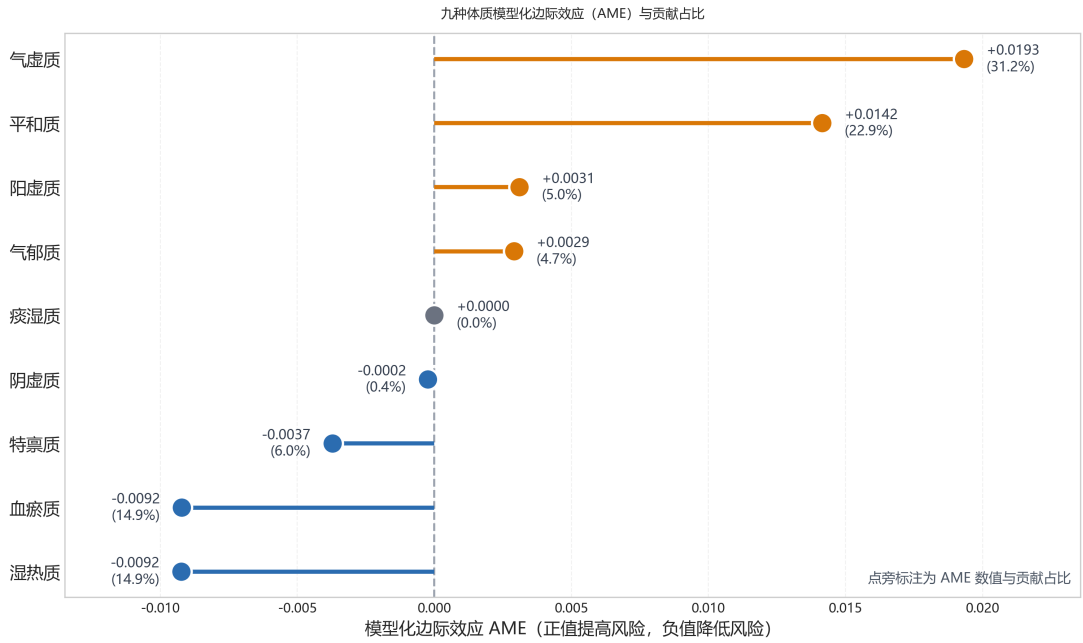

图 3 九种体质 AME 与风险贡献占比的可视化结果

六、问题二：多维风险预警模型的构建

6.1 双层风险预警框架

本文将问题二拆分为两个层次：

1. 诊断型模型：输入全部体质、活动能力、血脂、代谢和基础信息，输出当前高血脂风险概率；

2. 早预警模型：去除 TC、TG、LDL-C、HDL-C，仅保留体质、活动、代谢及生活方式信息，用于识别尚未完全表现为直接血脂异常的高风险个体.

两类模型均采用随机森林分类器. 为降低极端值和偏态分布的影响，模型训练前先在训练集上完成连续变量的分位截尾与对数变换，并加入 non-HDL-C、活动受限计数以及体质强度特征等派生变量. 如图 4 所示，诊断型模型主要回答“当前是否已接近或达到高血脂状态”，因此保留 non-HDL-C、TG 和 LDL-C 等直接反映脂质负担的变量；早预警模型则主要回答“在尚未出现明确血脂异常前，谁更可能向高风险演化”，因此删除直接血脂变量，只保留体质、活动、代谢与生活方式特征. 这样拆分后，两类模型分别承担“当前识别”和“前瞻筛查”两种不同任务.

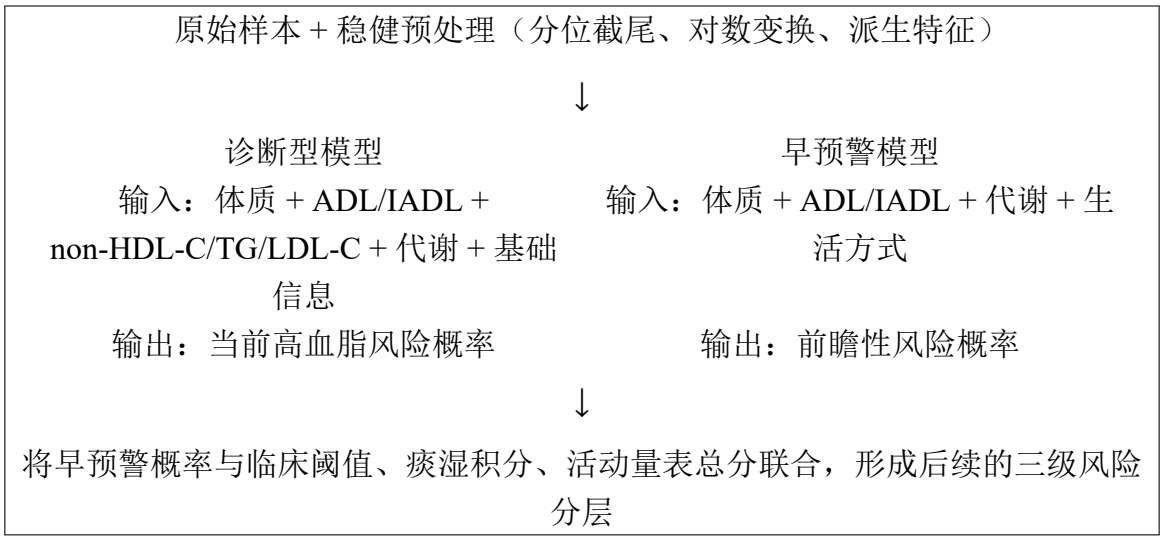

图 4 双层风险预警框架的输入–输出逻辑

样例数据上，诊断型模型的测试集 AUC 为 1.0000、准确率为 0.9840；早预警模型的测试集 AUC 为 0.8283、准确率为 0.7800. 这说明：若用于“确诊辅助识别”，诊断型模型以 non-HDL-C、TG 和 LDL-C 为核心脂质结构变量，已能够几乎完全刻画当前高血脂状态；若用于“未病先防”与早期筛查，则血尿酸、血糖、BMI 以及体质积分仍能提供稳定信号.

表 6 双层风险模型的测试效果

模型	AUC	准确率	说明
诊断型模型	1.0000	0.9840	经稳健预处理后几乎可完全识别当前已接近或达到高血脂诊断标准的患者
早预警模型	0.8283	0.7800	排除直接血脂指标后仍保持稳定效果，更适合基层筛查与提前干预

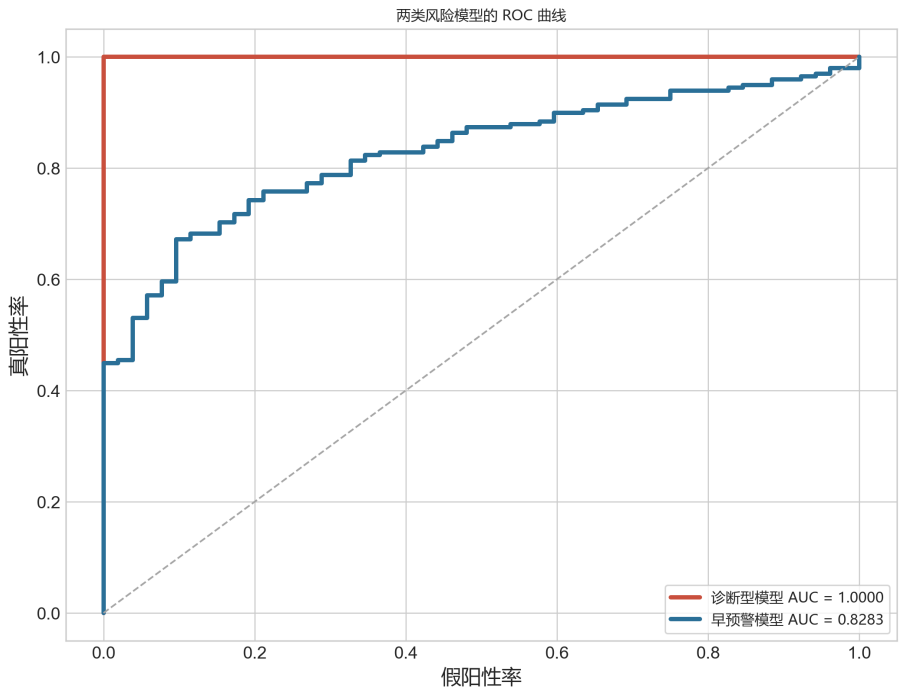

图 5 两类风险模型在测试集上的 ROC 曲线

图 5 给出了两类模型在测试集上的 ROC 曲线．可以看到，诊断型模型曲线几乎贴近左上角，说明其对“当前是否高血脂”的区分能力极强；早预警模型曲线虽然低于诊断型模型，但仍显著高于随机分类器，对基层筛查而言已经具有较好的可用性．

基于特征重要度，诊断型模型的前五位变量为 non-HDL-C、log(1 + TG)、log(1 + 血尿酸)、截尾后的 LDL-C 和截尾后的空腹血糖．早预警模型的前五位变量为 log(1 + 血尿酸)、截尾后的空腹血糖、截尾后的 BMI、血瘀质积分和阴虚质积分．换言之，诊断型模型主要抓取的是“当前脂质负担是否已经明显异常”；早预警模型更关注“代谢紊乱 + 体质偏颇 + 活动受限”这一前期风险结构．

表 7 脚本输出得到的两类模型前五重要特征

模型	前五重要特征
诊断型模型	non-HDL-C、log(1 + TG)、log(1 + 血尿酸)、截尾后的 LDL-C、截尾后的空腹血糖
早预警模型	log(1 + 血尿酸)、截尾后的空腹血糖、截尾后的 BMI、血瘀质积分、阴虚质积分

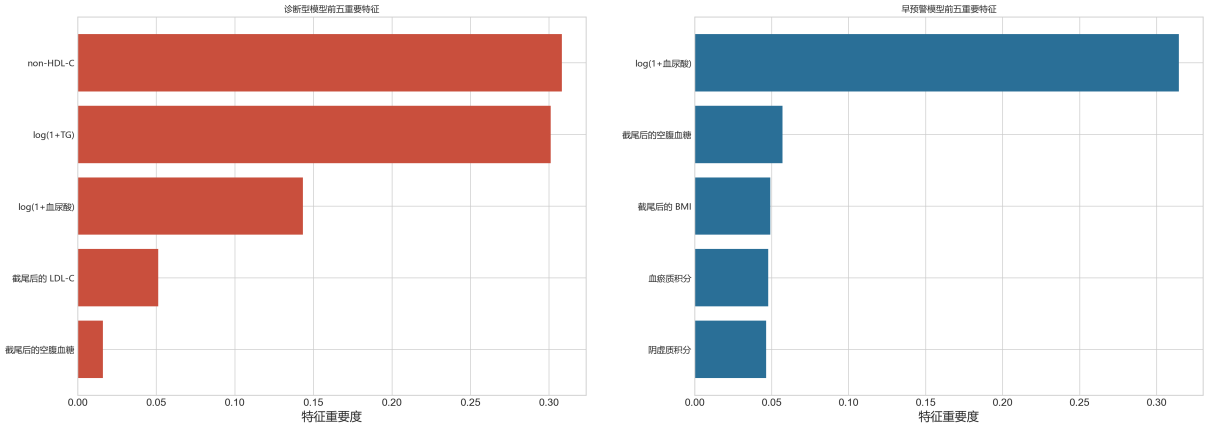

图 6 诊断型模型与早预警模型的前五重要特征

图 6 左右分别给出了诊断型模型和早预警模型的前五重要特征．两张特征重要度图进一步说明，两类模型依赖的信号并不相同：诊断型模型主要由 non-HDL-C、$\log(1+\mathrm{TG})$ 和 LDL-C 驱动，反映的是当前脂质负担；早预警模型则更多依赖血尿酸、血糖、BMI 以及血瘀质、阴虚质等体质信号，反映的是风险形成前期的代谢和体质结构．

仅给出基于节点不纯度下降的特征重要度，仍不足以说明某一变量究竟是在“抬高风险”还是在“压低风险”．为此，本文进一步对两类随机森林引入 TreeSHAP 解释．对第 i 个样本的正类预测概率 $\hat{p}_i$，其 SHAP 分解可写为

$$\hat{p}_i = \phi_0 + \sum_{j=1}^{d} \phi_{ij}, \tag{21}$$

其中 ϕ_0 为模型在背景样本上的基准正类概率，ϕ_{ij} 表示第 j 个特征对样本 i 的边际贡献；当 $\phi_{ij} > 0$ 时，该特征将预测结果推向更高的高血脂正类概率，当 $\phi_{ij} < 0$ 时，则说明该特征在当前样本上起到风险抑制作用．

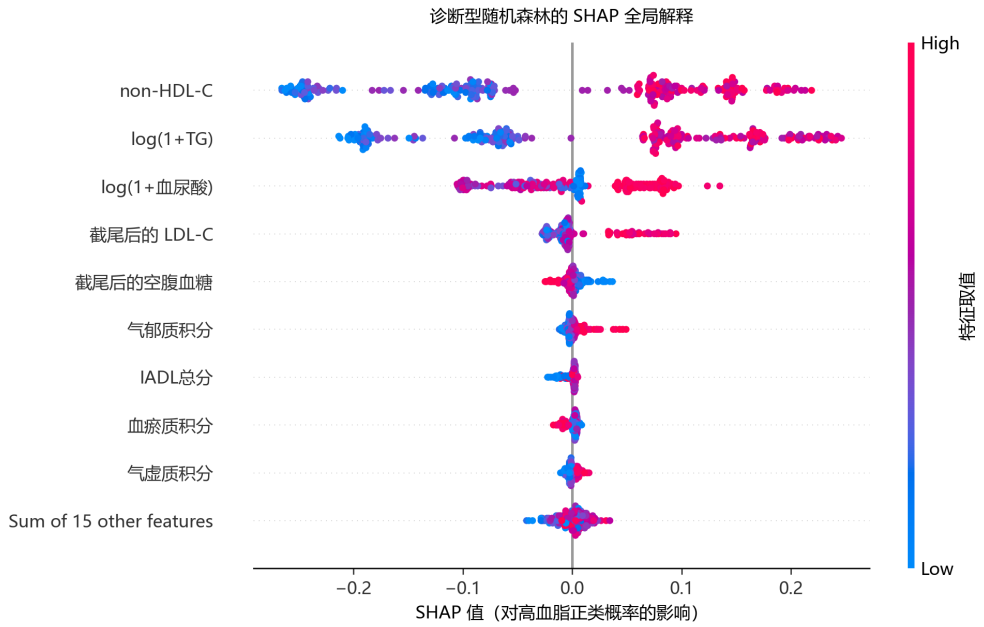

图 7 诊断型随机森林的 SHAP 全局解释

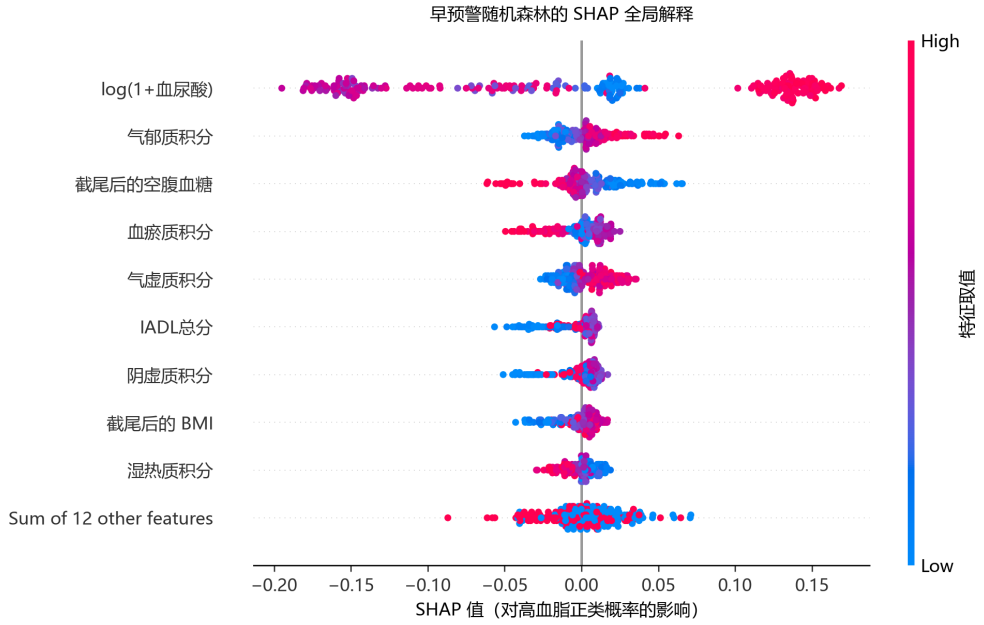

图 8　早预警随机森林的 SHAP 全局解释

从平均绝对 SHAP 值看，诊断型模型的前五位贡献变量为 non-HDL-C、log(1 + TG)、log(1 + 血尿酸)、截尾后的 LDL-C 和截尾后的空腹血糖，与前述特征重要度排序基本一致，说明该模型的核心判别依据仍是当前脂质负担．相比之下，早预警模型的前五位 SHAP 变量为 log(1 + 血尿酸)、气郁质积分、截尾后的空腹血糖、血瘀质积分和气虚质积分．图 7 与图 8 中每个点表示一个样本在该特征上的局部贡献：横坐标越靠右，说明该变量越倾向于将样本推向高血脂正类；颜色越红，则表示该样本在该特征上的取值越高．可以看到，诊断型模型的 SHAP 点云主要集中在 non-HDL-C 与 log(1 + TG) 上；早预警模型中血尿酸、气郁质、血瘀质等变量的推动更为分散，说明其识别的是“代谢紊乱 + 体质偏颇”的前期结构，而不是对单一血脂指标的重复判断．

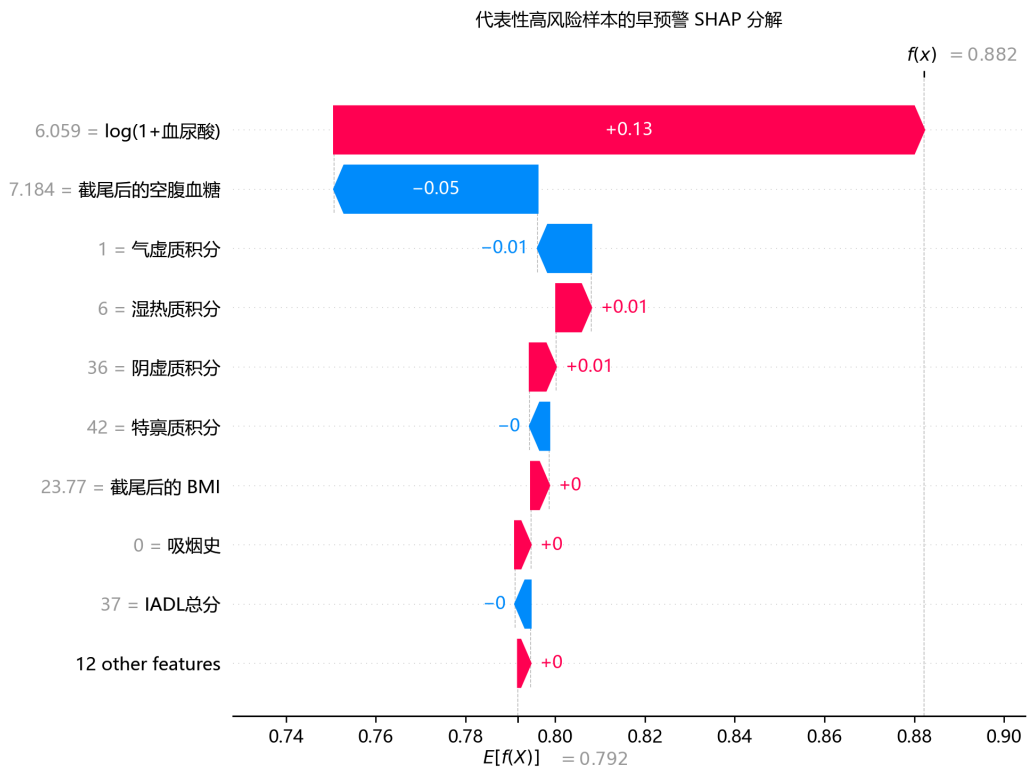

图 9 代表性潜在高风险个体的早预警 SHAP 分解

进一步地，图 9 给出了一个代表性潜在高风险个体的局部 SHAP 解释．该样本在测试集中不存在直接血脂异常项，且尚未被当前标签判为确诊病例，但早预警模型给出的正类概率仍达到 0.8823．从瀑布图可见，$\log(1+\text{血尿酸})$ 是最主要的正向推动因素，湿热质积分和阴虚质积分也对其高风险判断起到正向贡献；而空腹血糖和气虚质积分在该个体上呈现负向 SHAP 值，对总体风险起到一定抵消作用．这说明早预警模型并非简单依赖某个单一异常值，而是在多维特征共同作用下识别出“尚未明显血脂异常但已表现出潜在代谢–体质风险”的人群．

6.2 三级风险阈值设计

记样本的痰湿积分为 P，活动量表总分为 Q，血脂异常个数为 A，早预警模型输出概率为 $\hat{p}$．综合题目给出的临床正常区间与样例数据中学习到的风险规律，定义三级风险划分规则为

$$R = \begin{cases} \text{高风险}, & (A \geq 1 \wedge P \geq 60) \ \vee \ (A = 0 \wedge P \geq 80 \wedge Q < 40) \ \vee \ \hat{p} \geq 0.80, \\ \text{中风险}, & A \geq 1 \ \vee \ P \geq 60 \ \vee \ (\hat{p} \geq 0.45 \wedge Q < 60), \\ \text{低风险}, & \text{其余情形}. \end{cases} \tag{22}$$

其中，A 的计算依据为 TC、TG、LDL-C 是否超过题目给定上限，以及 HDL-C 是否低于题目给定下限．该规则兼顾了三方面信息：第一，临床血脂异常是最直接的危险信号；第二，痰湿积分高而活动能力低的人群，即便暂未表现出明显血脂异常，也可能处于早期高风险状态；第三，模型输出概率用来兜底吸收多变量之间的非线性交互关系．

表 8 三级风险分层阈值规则

风险等级	划分依据
低风险	血脂指标全部正常，痰湿积分 < 60，活动量表总分较高，且模型输出概率较低
中风险	至少存在一项血脂异常，或痰湿积分 ≥ 60，或模型概率达到中等水平且活动能力不足
高风险	满足“血脂异常 + 痰湿积分高”、“血脂正常但痰湿积分极高且活动能力很低”或模型概率 ≥ 0.80 的任一情形

按式 (22) 对样例数据分层后，低、中、高风险样本数分别为 59、292、649；在修正后主导体质标签为痰湿质的 292 例样本中，高风险人数为 207，占比达到 70.89%．为使上述阈值规则的判别逻辑更加直观，图 10 将三级风险分层中的主要人群流向绘制为 Sankey 图．该图以“是否存在血脂异常”为第一层划分，再结合痰湿积分与活动受限程度等关键条件，将样本逐步汇聚到高、中、低三类风险人群．可以看到，高风险样本主要由“血脂异常”分支贡献，而“血脂正常但痰湿极高且活动明显受限”的路径则补充识别出一部分早期高风险个体，这与式 (22) 的设计目的相一致．

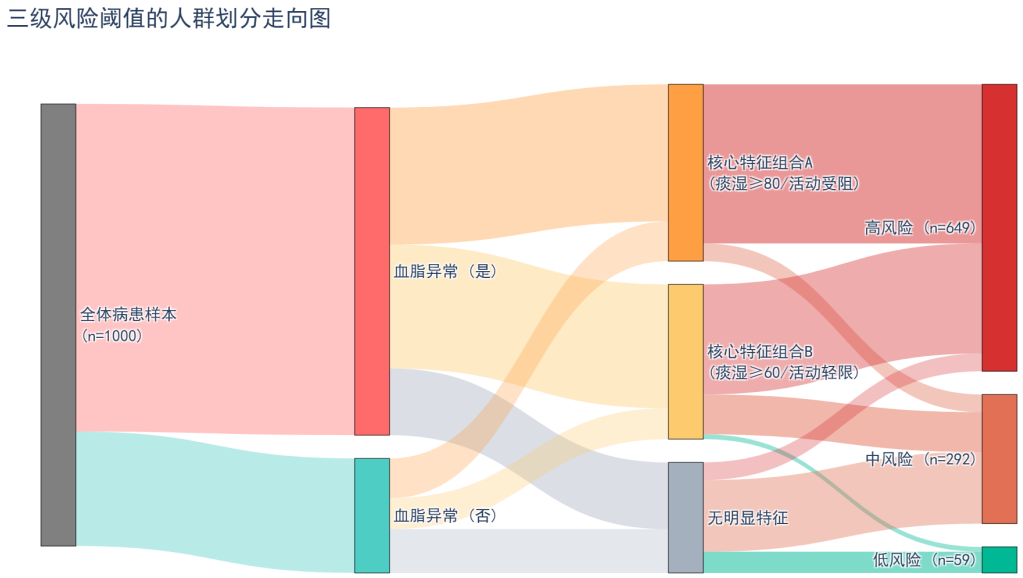

图 10 三级风险阈值下样本人群的主要划分走向

6.3 高风险核心特征组合识别

设高风险事件记为 $H = \{R = \text{高风险}\}$，为保证组合识别的可解释性，先将连续变量按临床阈值或分层阈值离散化为 8 个二值风险因子：

$$\begin{aligned} b_1 &= \mathbb{I}(A \geq 1), & b_2 &= \mathbb{I}(\mathrm{UA} > u_{\mathrm{UA}}(\mathrm{sex})), \\ b_3 &= \mathbb{I}(\mathrm{Glucose} > 6.1), & b_4 &= \mathbb{I}(\mathrm{BMI} > 23.9), \\ b_5 &= \mathbb{I}(\mathrm{Smoke} = 1), & b_6 &= \mathbb{I}(\mathrm{Drink} = 1), \\ b_7 &= \mathbb{I}(P \geq 60), & b_8 &= \mathbb{I}(Q < 60). \end{aligned} \tag{23}$$

其中 $u_{\mathrm{UA}}(\mathrm{sex})$ 为按性别取值的血尿酸正常上限，P 为痰湿积分，Q 为活动量表总分．随后在 $\{b_1, \ldots, b_8\}$ 上枚举全部二项组合与三项组合．对任一组合模式 C，定义其样本覆盖数、高风险覆盖数、条件置信度和提升度分别为

$$n(C) = \sum_{i=1}^{n} \mathbb{I}(C_i = 1), \qquad n_H(C) = \sum_{i=1}^{n} \mathbb{I}(C_i = 1, H_i = 1), \tag{24}$$

$$\mathrm{Conf}(C \Rightarrow H) = \frac{n_H(C)}{n(C)}, \qquad \mathrm{Lift}(C \Rightarrow H) = \frac{\mathrm{Conf}(C \Rightarrow H)}{\Pr(H)}. \tag{25}$$

这里 $\mathrm{Conf}(C \Rightarrow H)$ 表示“满足组合 C 的样本中，有多大比例被判为高风险”；$\mathrm{Lift}(C \Rightarrow H)$ 则衡量该组合相对于总体高风险基线概率的放大倍数．样例数据中总体高风险基线为

$$\Pr(H) = 649/1000 = 0.649.$$

为避免极小样本组合带来的偶然波动，本文仅保留满足 $n_H(C) \geq 80$ 且 $\mathrm{Lift}(C \Rightarrow H) > 1.05$ 的模式，再按 $n_H(C)$ 从大到小、$\mathrm{Lift}(C \Rightarrow H)$ 从大到小排序．

表 9 高风险核心特征组合的统计结果

组合类型	组合模式	高风险覆盖数 $n_H(C)$	置信度	提升度
二项组合	血脂异常 + 低活动量	521	0.804	1.239
二项组合	血脂异常 + 尿酸偏高	421	0.948	1.461
二项组合	尿酸偏高 + 低活动量	342	0.945	1.456
二项组合	血脂异常 + 饮酒史	324	0.798	1.230
二项组合	血脂异常 + 吸烟史	307	0.799	1.232
三项组合	血脂异常 + 尿酸偏高 + 低活动量	342	0.945	1.456
三项组合	血脂异常 + 饮酒史 + 低活动量	262	0.780	1.201
三项组合	血脂异常 + 吸烟史 + 低活动量	252	0.805	1.241
三项组合	血脂异常 + 尿酸偏高 + 饮酒史	209	0.946	1.457
三项组合	血脂异常 + 尿酸偏高 + 吸烟史	203	0.940	1.448

表 9 说明，高风险样本并不是由某一个单指标单独驱动的，而是主要表现为“血脂异常 + 代谢异常 + 行为/功能风险”的叠加结构．其中，“血脂异常 + 尿酸偏高”以及“血脂异常 + 尿酸偏高 + 低活动量”具有很高的置信度和提升度，说明尿酸异常在高风险识别中具有很强的协同放大作用；“血脂异常 + 吸烟/饮酒史”及其与低活动量的扩展组合则反映了生活方式风险的叠加效应．

需要特别说明的是，组合“血脂异常 + 痰湿积分高”虽然在样例中对应 110 个高风险样本，且置信度达到 1.000、提升度达到 1.541，但这与式 (22) 已将“血脂异常 + 痰湿积分高”直接纳入高风险条件有关．因此，它更适合作为规则驱动的确定性识别模式来解释，而不宜与上述高频组合一并视作完全独立的数据发掘结果．

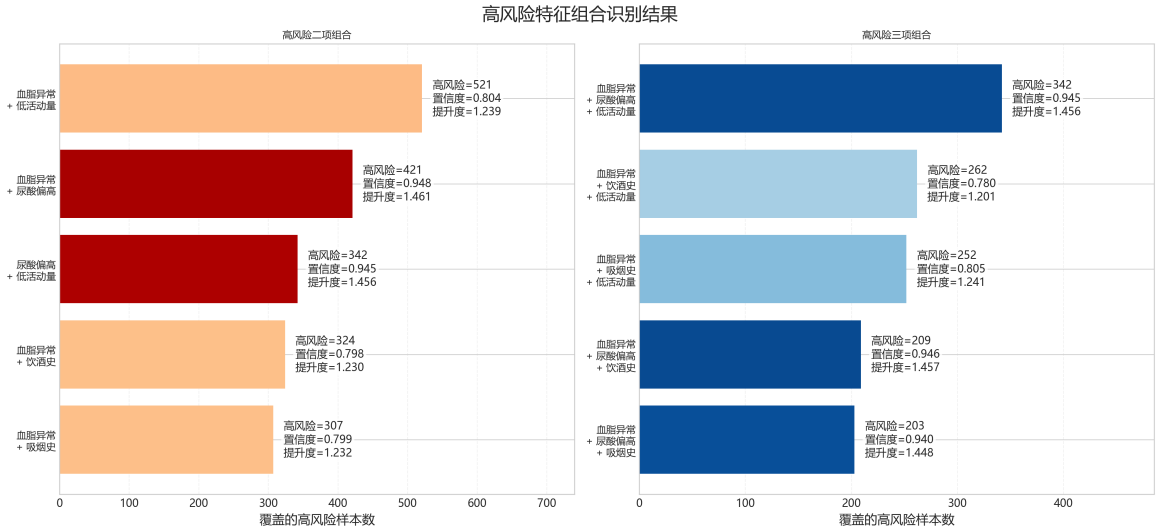

图 11 高风险特征组合的识别结果

图 11 左侧给出了高风险覆盖数最高的二项组合，右侧给出了高风险覆盖数最高的三项组合；柱长表示该组合覆盖的高风险样本数，颜色深浅对应提升度大小．可以看到，频数最高的模式大多围绕“血脂异常”展开，而当其与尿酸偏高、低活动量、吸烟史或饮酒史叠加时，组合的提升度会进一步上升．这说明高风险识别的核心并不是单一血脂超标，而是脂代谢异常、功能下降和不良生活方式共同构成的复合风险画像．

七、问题三：痰湿体质患者的六个月干预优化

7.1 决策变量与约束条件

对第三问要求的痰湿体质患者（体质标签为 5 ），记第 m 个月的活动干预强度为 u_m、每周训练频次为 f_m．根据题目要求：

1. 每个月的 u_m 均受年龄组和活动量表总分的双重约束；
2. $f_m \in \{1, 2, \ldots, 10\}$；
3. 六个月总成本不超过 2000 元；
4. 痰湿积分目标设为六个月后至少下降 10%，即 $s_6 \leq 0.9 s_0$．

这一达标条件同时参考了体质判定标准与临床最小有效改善阈值．根据《中医体质分类与判定》国家标准，偏颇体质转化分达到 40 分即可判为“是”，30–39 分判为“倾向是”[6]．对第三问涉及的患者进一步核验可知，附件样例数据中原始体质标签取值为 5 的患者，其痰湿积分均位于 55–65 分之间，明显高于 40 分判定线；因此一旦要求六个月后相对下降 10%，则绝对降分至少为 5.5 分．另一方面，朱燕波等基于 60/41/30 条目版本中医体质量表的综合校标法估算结果表明，痰湿质亚量表的最小临床重要差值约为 4 分[5]．由此可见，本文采用的 10% 目标不仅能够保证干预对象在国标意义下属于痰湿

偏颇人群，而且其对应的绝对降幅高于文献支持的 MCID 下限，从而避免将 1%–3% 的微小波动误判为“有效改善”．活动干预的月度降分比例定义为

$$r(u_m, f_m) = \begin{cases} 0, & f_m < 5, \\ 0.03(u_m - 1) + 0.01(f_m - 5), & f_m \geq 5. \end{cases} \tag{26}$$

于是痰湿积分的月度递推关系为

$$s_{m+1} = s_m\big(1 - r(u_m, f_m)\big), \qquad m = 0, 1, \ldots, 5. \tag{27}$$

中医调理等级根据当月积分自动匹配：0–58 分为一级、59–61 分为二级、≥ 62 分为三级．记对应月成本函数为 $c_{\mathrm{tcm}}(s_m)$；活动训练的单次成本为 c_{u_m}，则六个月总成本为

$$C = \sum_{m=1}^{6} \left[c_{\mathrm{tcm}}(s_{m-1}) + 4 f_m\, c_{u_m} \right]. \tag{28}$$

据此建立如下按月决策的优化模型：

$$\min_{\{u_m, f_m\}_{m=1}^{6}} C \tag{29}$$

满足

$$s_6 \leq 0.9 s_0, \qquad C \leq 2000, \qquad u_m \in \mathcal{I}(\text{年龄组}, Q), \qquad f_m \in \{1, \ldots, 10\}. \tag{30}$$

其中 $\mathcal{I}(\text{年龄组}, Q)$ 表示由年龄组和活动量表总分共同决定的允许强度集合．由于每个月的决策变量均为小规模离散变量，且转移仅依赖“当前月份 + 当前痰湿积分”，本文将第三问构造为动态规划问题．设 $V_m(x)$ 表示第 m 个月初痰湿积分为 x 时，从第 m 个月到第 6 个月达到目标所需的最小剩余成本，则有 Bellman 递推

$$V_m(x) = \min_{u \in \mathcal{I}(\text{年龄组}, Q),\, f \in \{1, \ldots, 10\}} \left\{ c_{\mathrm{tcm}}(x) + 4 f\, c_u + V_{m+1}\big(x(1 - r(u, f))\big) \right\}, \tag{31}$$

终止条件为

$$V_7(x) = \begin{cases} 0, & x \leq 0.9 s_0, \\ +\infty, & x > 0.9 s_0. \end{cases} \tag{32}$$

程序实现中将痰湿积分按 0.001 分精度离散化，并对具有相同月度降幅但成本更高的动作进行剔除，从而在有限状态空间内恢复最优的月度干预路径．

7.2 样本 1、2、3 的最优方案

采用上述动态规划模型求解，可得样本 1, 2, 3 的最优月度干预路径如表 10 所示．最优路径均表现出明显的阶段性：前期利用较高强度或较高频次快速降分并尽早降低中医调理等级，后期则转入低成本维持．

表 10 样本 1、2、3 的六个月最优干预方案

样本 ID	初始痰湿积分	目标上限	活动总分	阶段性最优方案	总成本 / 期末积分
1	64.0	57.6	38	1–2 月：(1, 10)；3 月：(1, 6)；4–6 月：(1, 1)	678 元 / 57.18
2	58.0	52.2	40	1 月：(2, 8)；2 月：(1, 10)；3–6 月：(1, 1)	508 元 / 51.79
3	59.0	53.1	63	1 月：(2, 8)；2 月：(1, 10)；3–6 月：(1, 1)	558 元 / 52.69

表中 (u, f) 分别表示“当月活动干预强度”和“每周训练频次”．为便于展示三位样本在六个月内的积分变化轨迹与成本累积趋势，图 12 预留了三位患者的干预执行轨迹图位．需要特别说明的是，该图当前仍沿用队友按“六个月固定同一方案”口径制作的旧版示意，因此仅作为版式占位；正式提交前，应按本文动态规划得到的阶段性最优方案重新绘制并替换．

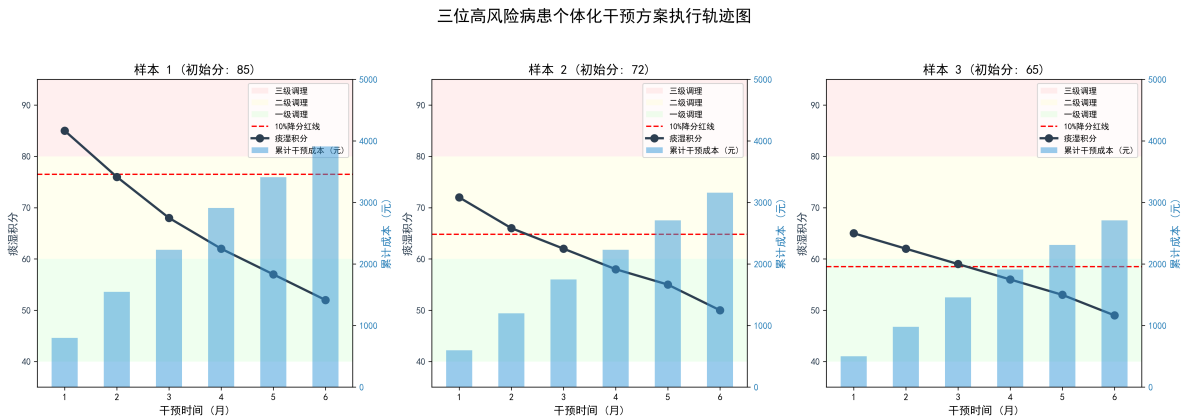

图 12 三位样本六个月干预轨迹与成本变化示意

从结果可以看出，样本 1 因活动总分仅为 38，全程只能选一级强度，因此动态规划给出的策略是先连续两个月采用高频训练，再用一个月中频训练将积分压到目标线以下，最后转入最低频次维持；样本 2 和样本 3 的活动总分分别为 40 和 63，允许使用二级强度，于是最优路径都选择在首月使用“二级强度 + 每周 8 次”快速跨越调理分级边界，次月改用“一级强度 + 每周 10 次”继续降分，之后以“一级强度 + 每周 1 次”维持即可．由此可见，动态规划自动识别出的经济策略是“前期快速降分、后期低成本维持”．

7.3 患者特征与最优方案的匹配规律

综合所有可行方案的搜索结果，可以总结出如下匹配规律：

1. 若年龄较大或活动量表总分偏低，则强度选择空间被压缩，此时更可能形成“低强度 + 前期高频 + 后期维持”的路径；

2. 若初始痰湿积分处于 58–62 分附近，则首月尽快跨越调理等级边界可以显著降低后续月成本，因此前期适度强化往往更划算；

3. 若患者活动能力允许选择二级强度，但目标仅为 10% 左右的中等降幅，则短期使用二级强度常优于长期维持高频一级强度；

4. 预算约束下，最优策略通常呈现“前期集中降分、后期低成本维持”的阶段式结构，而非六个月固定同一方案.

图 13 给出了一个“患者特征–干预策略”的速查图位，用于后续展示初始痰湿积分区间、活动能力区间与推荐策略之间的对应关系. 由于该图当前仍使用旧版固定方案口径下的预估成本标注，因此此处先作为占位保留，待队友按动态规划结果重绘后即可直接替换同名图片文件.

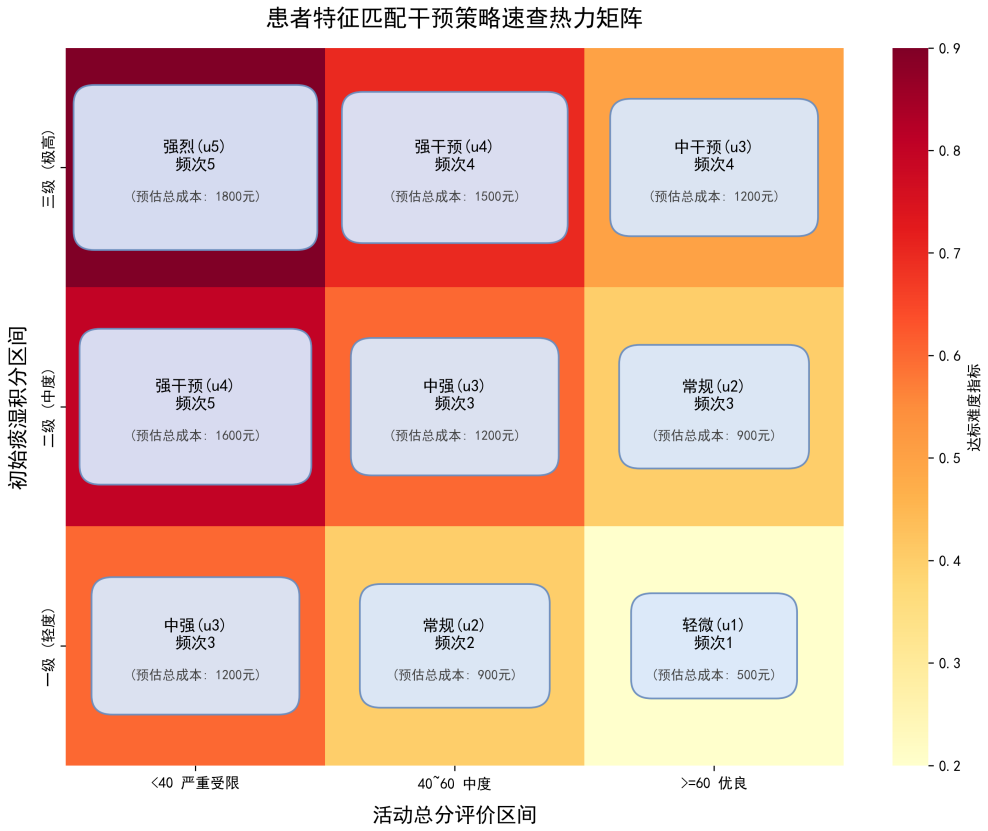

图 13 患者特征与最优干预策略速查图

八、模型检验与结果讨论

本文模型的检验主要从三个角度展开.

1. **结果一致性检验**：诊断型模型的重要特征集中在 TG、non-HDL-C、LDL-C 及少量代谢变量，与高血脂临床诊断中“甘油三酯异常 + 非 HDL 胆固醇负担 + LDL 负担”的识别逻辑一致；早预警模型的重要特征集中在血尿酸、血糖、BMI 和体质、活动变量，与慢病早筛的医学常识相符.

2. **阈值可解释性检验**：三级风险阈值同时引用了临床正常值区间、痰湿积分与活动能力规则，不依赖黑盒模型单独输出，便于基层使用者理解与执行.

3. **干预可行性检验**：样本 1, 2, 3 的最优方案均满足年龄约束、活动能力约束和预算约束，且最终痰湿积分均达到既定目标，说明优化模型具有实际可操作性.

进一步地，为将问题二中的风险分层规则整理为更便于社区卫生服务人员理解和执行的操作流程，图 14 给出了一个综合风险评估流程示意. 该图将“重症并发症预警优先筛出”和“常规人群进入风险矩阵评估”两条路径串联起来，强调的是基层场景下的判读顺序与落地逻辑；其中涉及的分层判断仍以式 (22)、表 8 及问题二的统计结果为正式依据.

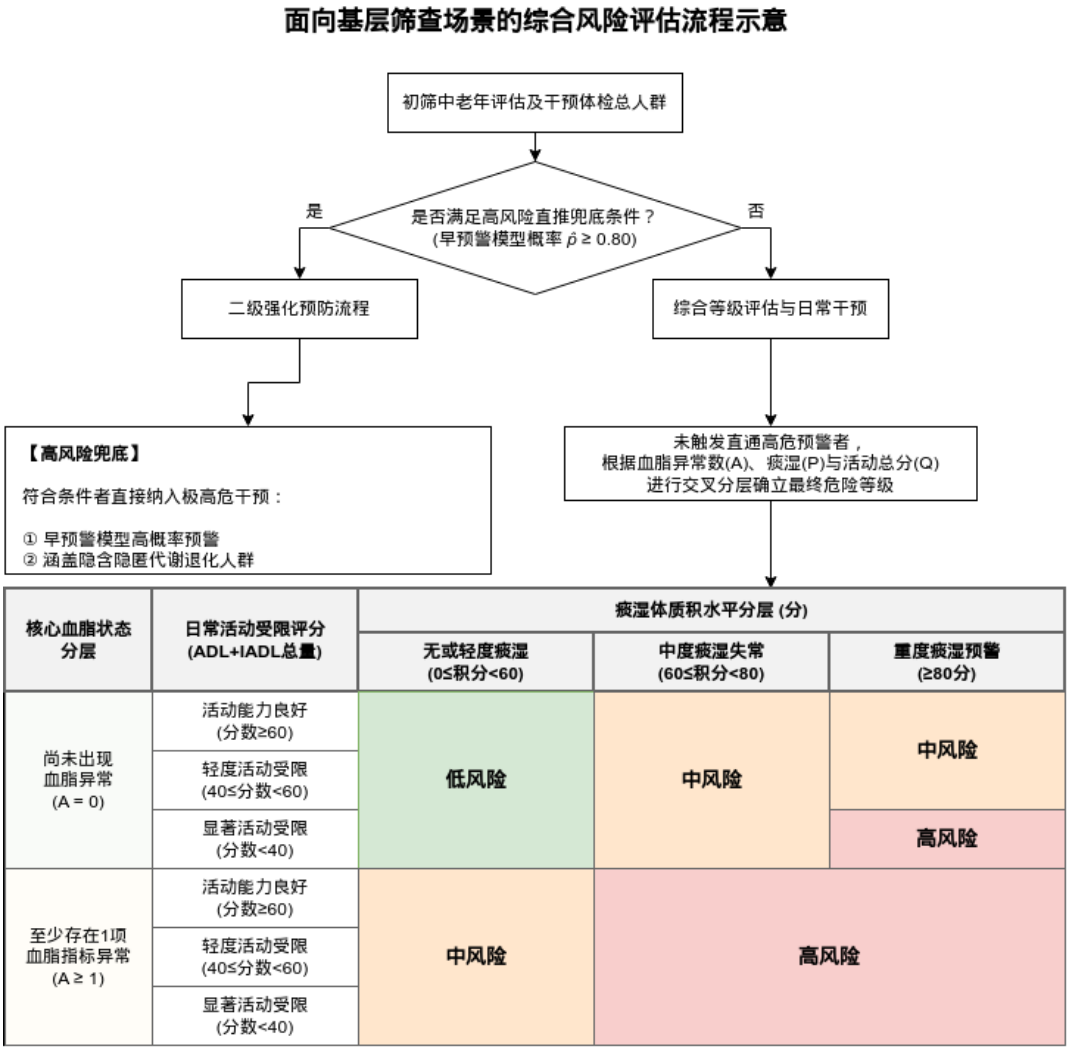

图 14 面向基层筛查场景的综合风险评估流程示意

需要指出的是，样例数据中确诊样本占比达到 79.3%，类别分布并不均衡，这会抬高部分单体质组的表观确诊率. 因此，在解释主导体质组的表观确诊率和部分组合模式时，应更关注相对比较关系，而不宜将其直接理解为严格的总体患病率估计.

九、模型评价

9.1 模型优点

1. 将“诊断识别”和“未病预警”分开建模，避免直接血脂指标掩盖其他变量的预警价值；
2. 风险等级规则可解释性强，便于在社区卫生服务场景中落地；
3. 干预模型直接嵌入了题目给定的强度、频次、年龄与预算约束，输出方案具有较强操作性；
4. 建模流程统一，问题一的筛选结果可自然过渡到问题二和问题三.

9.2 模型不足

1. 中医调理等级只给出了成本标准，未给出独立的降分函数，因此本文将其作为基础成本而非单独的收益项；
2. 活动干预效果采用固定月度下降比例，虽然月度决策已允许动态调整，但仍未考虑患者依从性波动和边际收益递减；
3. 样例数据存在类别不平衡现象，且不同体质之间可能存在多重共线性，使单体质贡献的解释受到一定干扰.

参考文献

[1] 2026 年第十六届 MathorCup 数学应用挑战赛 C 题：中老年人群高血脂症的风险预警及干预方案优化.

[2] Breiman L. Random Forests[J]. Machine Learning, 2001, 45(1): 5-32.

[3] Hastie T, Tibshirani R, Friedman J. The Elements of Statistical Learning[M]. New York: Springer, 2009.

[4] Bishop C M. Pattern Recognition and Machine Learning[M]. New York: Springer, 2006.

[5] 朱燕波, 丛建妮, 史会梅. 3 个不同条目版本中医体质量表的最小临床重要差值研究[J]. 北京中医药大学学报, 2023, 46(5).

[6] GB/T 46939—2025. 中医体质分类与判定 [S]. 2025.

附　录

附录 1：算法实现说明

本文当前用于结果整理与论文回填的程序化实现文件位于赛题/C 题目录下．其文件名为 c_problem_starter.py，主要完成以下功能：

1. 使用 pandas.read_excel() 直接读取附件中的 xlsx 文件，并将中文列名映射为便于建模的英文列名；
2. 计算问题一中的综合筛选得分、体质风险差异；
3. 训练问题二中的诊断型模型与早预警模型，并输出三级风险分层结果；
4. 使用动态规划求解问题三中的月度强度与频次路径，并输出指定患者的最优阶段性方案．

该脚本同时也是 notebook 逐段拆解版本对应的唯一主脚本，后续结果复现实验均以它为准．

附录 2：问题三核心求解伪代码

```
for each patient in phlegm_damp_group:
    actions = nondominated_monthly_actions(age_group, activity_score)
    states = {round(baseline_phlegm_score, 3): 0}
    parents = []
    for month in range(1, 7):
        next_states = {}
        parent_map = {}
        for score, cost in states.items():
            level = tcm_level(score)
            for action in actions:
                next_score = discretize(score * (1 - drop_ratio(action)))
                next_cost = cost + tcm_monthly_cost[level] + train_cost(action)
                if next_score not in next_states or next_cost < next_states[
                    next_score]:
                    next_states[next_score] = next_cost
                    parent_map[next_score] = (score, action)
        states = next_states
        parents.append(parent_map)
    choose terminal state with:
        1) target and budget satisfied first
        2) lower total cost
        3) lower final score
    backtrack parents to recover the 6-month plan
```