队伍编号	XXXXXX
题号	C

中老年人群高血脂症的风险预警及干预方案优化

摘 要

针对中老年人群高血脂症的早筛、分层预警与个体化干预问题，本文基于附件中的1000例样本数据，构建了“关键指标筛选–三级风险预警–六个月干预优化”的一体化建模框架．首先，围绕痰湿积分与高血脂确诊标签两个目标，分别计算候选指标与痰湿严重程度的Spearman相关系数、互信息，以及随机森林特征重要度，并采用等权综合评分筛选关键指标．结果表明，血脂指标中的TG、TC、LDL-C、HDL-C对确诊风险具有最直接的解释力，而在去除直接诊断性血脂指标后，血尿酸、血糖、BMI、活动能力总分及体质积分仍保留较强的预警价值．其次，本文在风险模型训练前加入了数据核验、训练集分位截尾、偏态变量对数变换以及non-HDL-C、活动受限计数等派生特征构造步骤，并在诊断型模型中将脂质结构变量收口为non-HDL-C、TG和LDL-C组合，以削弱极端值和结构性冗余带来的扰动．在样例数据上，诊断型模型测试集AUC达到1.0000，去除TC/TG/LDL-C/HDL-C后的早预警模型AUC仍达到0.8283，说明经稳健预处理后，多维度特征融合可实现更稳定的风险判别．结合临床正常值区间、痰湿积分阈值与活动能力约束，本文进一步给出了低、中、高三级风险阈值规则，并提炼出“血脂异常 + 尿酸偏高”、“血脂异常 + 吸烟/饮酒史”、“痰湿积分高 + 活动能力低”等核心高风险特征组合．最后，针对痰湿体质患者，本文建立以干预强度和每周频次为决策变量的六个月优化模型，在年龄约束、活动能力约束及总成本不超过2000元的条件下，以最小成本达到既定降分目标．对样本ID为$1,2,3$的患者求解得到的最优方案分别为$(1,10)$、$(1,7)$、$(1,7)$，均能在预算内完成至少10%的痰湿积分下降目标．本文方法兼顾可解释性、可计算性与落地性，可为基层慢病管理中的风险筛查与干预决策提供定量依据．

关键词：高血脂症，痰湿体质，风险预警，随机森林，干预优化

目录

一、 问题重述 1
二、 数据理解与总体思路 1
2.1 数据核验与预处理 2
三、 模型假设 3
四、 符号说明 3
五、 问题一：关键指标筛选与体质贡献分析 4
5.1 双目标筛选思路与评价指标 4
5.2 关键指标筛选结果及解释 5
5.3 九种体质的风险贡献差异 7
六、 问题二：多维风险预警模型的构建 9
6.1 双层风险预警框架 9
6.2 三级风险阈值设计 12
6.3 高风险核心特征组合识别 13
七、 问题三：痰湿体质患者的六个月干预优化 13
7.1 决策变量与约束条件 13
7.2 样本 1、2、3 的最优方案 14
7.3 患者特征与最优方案的匹配规律 14
八、 模型检验与结果讨论 15
九、 模型评价与改进方向 15
9.1 模型优点 15
9.2 模型不足 15
9.3 改进方向 16
参考文献 16
附录 1： 算法实现说明 17
附录 2： 问题三核心求解伪代码 17

一、问题重述

高血脂症是中老年群体中最常见的慢性代谢性疾病之一，既与常规血脂指标直接相关，又与中医体质偏颇、活动能力下降、生活方式不良等因素存在显著耦合．题目给出了九种体质标签及积分、ADL/IADL 活动能力评分、血脂与代谢指标、生活习惯信息以及高血脂确诊标签，要求完成三个层面的任务：

1. 从血常规体检指标和活动能力指标中筛选既能表征痰湿体质严重程度、又能预警高血脂风险的关键指标，并研究九种体质对高血脂风险的贡献差异．
2. 构建融合多维特征的三级风险预警模型，给出低、中、高风险的阈值划分依据，并识别痰湿体质高风险人群的核心特征组合．
3. 对体质标签为 5 的痰湿体质患者设计六个月干预方案，在满足年龄、活动能力和预算约束的情况下，以较低成本实现痰湿积分下降目标，并给出样本 ID 为 $1, 2, 3$ 的最优方案．

二、数据理解与总体思路

附件数据共包含 1000 例样本、37 个字段，无缺失值；其中高血脂确诊样本 793 例，未确诊样本 207 例．将主导体质标签按九种体质积分最大项修正后，痰湿体质样本数最多，共 292 例．整体来看，数据具有两个鲜明特征：其一，血脂指标与确诊标签高度同源，若直接用于分类，会得到非常高的判别精度；其二，活动能力、代谢异常与体质积分在排除直接血脂指标后，仍具有提前预警价值．因此本文采用图 1 所示的双层建模思路：

1. 问题一侧重“筛指标”和“看差异”，从统计相关性、信息量和树模型重要度三个角度联合打分；
2. 问题二将风险识别划分为“诊断型识别”和“早预警识别”，前者追求精度，后者强调前瞻性与可解释阈值；
3. 问题三把中医调理等级视为随痰湿积分动态变化的基础成本，把活动干预强度和频次作为优化变量，建立约束优化模型．

数据预处理 → 多指标筛选 → 体质贡献分析 → 双层风险预警

↓

分层阈值设计 → 高风险组合识别 → 干预优化求解 → 个体方案输出

图 1 本文的总体建模流程

2.1 数据核验与预处理

虽然样例数据没有缺失值和重复样本，但直接“读入即建模”仍然不够稳健．为此，本文在建模前加入了结构核验与稳健预处理两层步骤．

首先，对原始字段进行一致性检查．结果表明：ADL 五个子题项之和与 ADL 总分完全一致，IADL 五个子题项之和与 IADL 总分完全一致，且 ADL 总分与 IADL 总分之和与活动量表总分完全一致；高血脂二分类标签为 0 时，分型标签均为 0，说明标签系统内部协调．但同时发现，原始主导体质标签与九种体质积分最大项并不总是完全一致，样例中共有 65 例样本存在不一致现象．考虑到题目中的“主导体质标签”本应表示九种体质中的主导类型，本文将这 65 例视为标签异常，并统一按九种体质积分最大项对主导体质标签进行修正；其余 935 例样本原标签与积分最大项一致．

其次，对进入问题二风险模型的连续变量实施稳健化处理．考虑到 TG、血尿酸、BMI 等变量存在偏态与极端值扰动，本文仅在训练集上估计 1% 与 99% 分位点，并据此对 HDL-C、LDL-C、TG、TC、空腹血糖、血尿酸和 BMI 进行分位截尾，再将同样的阈值应用于测试集，以避免数据泄漏．设连续变量 x 在训练集上的 1% 与 99% 分位点分别为 $q_{0.01}(x)$ 与 $q_{0.99}(x)$，则其稳健化后的截尾变量定义为

$$x_i^{(w)} = \min\left\{\max\left(x_i, q_{0.01}(x)\right), q_{0.99}(x)\right\}. \tag{1}$$

在此基础上，对右偏更明显的 TG 和血尿酸进一步做对数变换：

$$\mathrm{TG}_i^{(\log)} = \log\left(1 + \mathrm{TG}_i^{(w)}\right), \qquad \mathrm{UA}_i^{(\log)} = \log\left(1 + \mathrm{UA}_i^{(w)}\right). \tag{2}$$

同时构造 non-HDL-C 这一脂质结构变量：

$$\mathrm{nonHDL}_i = \mathrm{TC}_i^{(w)} - \mathrm{HDL}_i^{(w)}. \tag{3}$$

考虑到 non-HDL-C 与 TC、HDL-C 存在线性确定关系，若再同时引入 TC/HDL-C、LDL-C/HDL-C、TG/HDL-C 等派生比值，会放大同一脂质家族的重复表达．因此，本文在诊断型模型中仅保留 non-HDL-C、TG 和 LDL-C 这一组脂质组合，用 non-HDL-C 概括总胆固醇与保护性胆固醇的净失衡程度，用 TG 表征甘油三酯异常，用 LDL-C 表征低密度脂蛋白负担，从而兼顾医学解释性与变量独立性．

最后，针对活动能力和体质信息加入结构化派生变量．活动变量中，由于 ADL/IADL 子题项与总分之间存在严格加总关系，本文在问题二模型中不再同时放入全部子题项与总分，而是保留 ADL 总分、IADL 总分，并额外构造“活动受限题项数”以补充局部功能损伤信息．设 10 个 ADL/IADL 子题项记为 a_{ij}，经验阈值取 $\tau = 8$，则第 i 个样本的活动受限计数定义为

$$C_i^{(\mathrm{act})} = \sum_{j=1}^{10} \mathbb{I}(a_{ij} < \tau), \tag{4}$$

其中 $\mathbb{I}(\cdot)$ 为指示函数．该变量反映的是“低分题项有多少个”，因此它补充的是总分无法直接表达的受限范围信息．

体质变量中，设第 i 个样本的九种体质积分排序后最大值与次大值分别为 $s_{i(1)}$ 和 $s_{i(2)}$，则进一步构造

$$S_i^{(\max)} = s_{i(1)}, \qquad M_i^{(\mathrm{gap})} = s_{i(1)} - s_{i(2)}, \tag{5}$$

分别表示“最强体质倾向的绝对强度”和“第一体质与第二体质之间的优势差距”．由于主导体质标签已在数据核验阶段按积分最大项完成修正，后续建模不再单独构造标签一致性标记．这样处理后，既保留了医学解释性，又降低了冗余表达和极端值对随机森林训练的干扰．需要说明的是，问题一的排序对象仍保持为原始血常规和活动量表指标，上述稳健化步骤主要用于问题二的预测模型与风险分层．

三、模型假设

1. 附件样本已完成临床检验与标签标注，数据可直接用于建模与验证．
2. 题目给出的临床正常值区间与活动能力约束规则具有统一适用性，视为风险分层与干预求解的硬约束．
3. 痰湿积分每月变化主要由活动干预强度与频次驱动；中医调理等级在题目中未给出显式降分系数，因此本文将其视为按积分区间自动匹配的基础调理成本．
4. 在相同活动干预强度下，若每周训练频次低于 5 次，则痰湿积分近似保持稳定；若每周训练频次不低于 5 次，则按题目给出的比例规则递推下降．
5. 六个月周期内患者的年龄组、性别以及吸烟饮酒史不发生变化，活动量表初值用于确定可选强度上界．

四、符号说明

符号	含义
x_{ij}	第 i 个样本在第 j 个候选指标上的观测值
P_i	第 i 个样本的痰湿积分
y_i	第 i 个样本的高血脂二分类标签
S_j	第 j 个候选指标的综合筛选得分
L_k	第 k 类主导体质对应的风险提升度
$\hat{p}_i$	风险预警模型对样本 i 输出的高血脂风险概率
R_i	样本 i 的三级风险等级
u	活动干预强度等级，$u \in \{1, 2, 3\}$
f	每周训练频次，$f \in \{1, 2, \ldots, 10\}$
s_m	第 m 个月末的痰湿积分
$r(u, f)$	在强度 u、频次 f 下的月度痰湿降幅比例
C	六个月总干预成本

五、问题一：关键指标筛选与体质贡献分析

5.1 双目标筛选思路与评价指标

问题一并不是单纯寻找“与痰湿积分最相关”的变量，而是要从血常规体检指标和活动量表评分中筛出一组既能刻画痰湿偏颇程度、又能预警高血脂发病风险的关键指标．因此，本文将其视为一个双目标筛选问题．需要首先说明的是，活动能力变量之间存在明显的结构性共线性：ADL 总分是 5 个 ADL 子题项之和，IADL 总分是 5 个 IADL 子题项之和，而活动量表总分又等于 ADL 总分与 IADL 总分之和．若将总分、整体总分和全部子题项同时放入同一候选池，会导致功能能力维度被重复计分．因此，本文采用分层处理策略：主分析只保留 ADL 总分和 IADL 总分；活动量表总分作为后续问题二风险分层和问题三强度约束的派生变量，不参与问题一主排序．同时，为了检验是否存在某个子题项能够明显优于总分变量，补充分析中再将 10 个 ADL/IADL 子题项与 HDL-C、LDL-C、TG、TC、空腹血糖、血尿酸、BMI 一并放入同一候选池重新排序．基于这一处理，主分析的候选变量集合记为

$$\begin{aligned} X = \{&\text{ADL 总分、IADL 总分、HDL-C、LDL-C、TG、TC,} \\ &\text{空腹血糖、血尿酸、BMI}\}. \end{aligned} \tag{6}$$

其中每个候选变量记为 x_j，痰湿积分记为 P，高血脂二分类标签记为 y．对每个候选变量，本文从“单变量相关性”“非线性信息量”和“多变量联合重要度”三个角度进行评价．

首先，为了衡量候选指标对痰湿积分的单调关联程度，计算 Spearman 秩相关系数，并取其绝对值

$$R_j = \left|\rho_s(x_j, P)\right|. \tag{7}$$

这里取绝对值，是因为问题一关心的是“关联强弱”而非“正负方向”．例如 HDL-C 或活动量表总分可能与痰湿积分呈负相关，但这类负向指标同样具有很强的风险识别意义，不能因为方向为负就被排除．

其次，为了避免仅依赖线性或单调关系，进一步计算互信息指标：

$$M_j^{(1)} = I(x_j; P), \qquad M_j^{(2)} = I(x_j; y), \tag{8}$$

其中 $M_j^{(1)}$ 衡量指标对痰湿积分的非线性解释能力，$M_j^{(2)}$ 衡量指标对高血脂标签的非线性预警能力．

再次，为了考察变量之间交互作用下的多变量联合贡献，分别建立随机森林回归模型和随机森林分类模型：

$$P = f_{\text{RF-reg}}(X), \qquad y = f_{\text{RF-clf}}(X), \tag{9}$$

并提取各候选变量在两类模型中的重要度，记为

$$F_j^{(1)}, \qquad F_j^{(2)}. \tag{10}$$

综上，每个候选指标共得到五类评价量：

$$R_j, \quad M_j^{(1)}, \quad M_j^{(2)}, \quad F_j^{(1)}, \quad F_j^{(2)}. \tag{11}$$

由于这五类统计量量纲不同，且其中有的反映相关强度、有的反映信息量、有的反映树模型重要度，本文不直接对原值加权，而是先分别排序，再进行积分汇总．设共有 q 个候选指标，若第 j 个指标在第 m 类评价下的名次为 $\mathrm{rank}_j^{(m)}$，则定义其名次得分为

$$s_j^{(m)} = q - \mathrm{rank}_j^{(m)} + 1. \tag{12}$$

最终综合筛选得分定义为

$$S_j = \sum_{m=1}^{5} s_j^{(m)}. \tag{13}$$

本文主分析共有 $q = 9$ 个候选指标，因此在某一评价维度下排名第 1、2、9 位的指标，分别得到 9、8、1 分．S_j 越大，说明该指标在五种评价视角下越稳定地靠前，也就越适合同时承担“体质刻画”和“风险预警”两类任务．这种“排序积分”的处理方式比直接对原值做线性加权更稳健，也更符合程序实现．

5.2 关键指标筛选结果及解释

基于上述流程，主分析中 9 个候选指标的综合排序结果依次为 TC、TG、BMI、HDL-C、ADL 总分、LDL-C、空腹血糖、IADL 总分和血尿酸．换言之，本文不是直接“把这些指标列出来”，而是先让每个指标分别在五个维度上独立排序，再看其总积分是否持续靠前．例如，TC 在五类评价中的名次分别为 $2, 7, 3, 4, 1$，因此综合得分为

$$S_{\mathrm{TC}} = (9-2+1) + (9-7+1) + (9-3+1) + (9-4+1) + (9-1+1) = 33. \tag{14}$$

同理，ADL 总分在五类评价中的名次分别为 $1, 2, 7, 8, 9$，因此综合得分为 23．这说明 TC、TG 等直接血脂指标在高血脂分类任务上极强，因此排在前列；而 ADL 总分虽然对高血脂标签的单项判别力不如血脂指标，但它在痰湿积分相关性和回归解释能力上持续靠前，因此仍被保留为核心功能指标．

表 1 问题一主分析 9 个候选指标在五类评价下的名次与综合得分

指标	Spearman	MI-回归	MI-分类	RF-回归	RF-分类	综合得分
TC	2	7	3	4	1	33
TG	6	6	1	5	2	30
BMI	3	1	9	1	7	29
HDL-C	7	5	4	3	5	26
ADL 总分	1	2	7	8	9	23
LDL-C	8	4	5	6	4	23
空腹血糖	5	8	8	2	6	21
IADL 总分	4	3	6	9	8	20
血尿酸	9	9	2	7	3	20

表 1 说明，在处理了活动能力维度的结构性共线性之后，问题一主分析的排序结果更加集中于九个无重复候选变量．直接血脂指标在高血脂分类任务上占据优势，因此 TC、TG、HDL-C、LDL-C 稳定居前；BMI、空腹血糖和血尿酸则体现出代谢协同作用；ADL 总分和 IADL 总分说明总体功能状态仍然能够提供对痰湿偏颇和风险水平的联合信息．

作为补充分析，本文又构造了一个“子题项替代总分”的混合候选池：用 10 个 ADL/IADL 子题项替代 ADL 总分与 IADL 总分，并与 HDL-C、LDL-C、TG、TC、空腹血糖、血尿酸、BMI 一起重新进行五维排序．结果表明，在这一混合池中，排序靠前的指标依次为 TC、TG、ADL 吃饭、BMI、HDL-C、ADL 用厕、LDL-C、血尿酸、IADL 理财和 ADL 洗澡．其中，ADL 吃饭和 ADL 用厕确实表现出较强信号，说明某些基础生活自理条目能够比总分更敏锐地刻画痰湿偏颇与代谢风险．

表 2 问题一补充分析中混合候选池的前十指标

指标	Spearman	MI-回归	MI-分类	RF-回归	RF-分类	综合得分
TC	3	15	3	4	2	63
TG	10	14	1	3	1	61
ADL 吃饭	1	6	8	8	8	59
BMI	7	1	17	1	6	58
HDL-C	11	13	4	5	5	52
ADL 用厕	2	7	7	9	16	49
LDL-C	13	12	5	7	4	49
血尿酸	14	17	2	6	3	48
IADL 理财	5	2	11	10	14	48
ADL 洗澡	4	4	14	11	13	44

表 2 说明，子题项层面确实存在表现突出的变量，尤其是 ADL 吃饭和 ADL 用厕；这意味着如果研究重点偏向“解释具体行为功能与痰湿偏颇的关系”，完全可以采用子题项层分析口径．然而，从本题整体求解链条看，问题二中的风险阈值与问题三中的活动强度约束都直接依赖总分变量，而混合候选池中也未出现多个子题项在各维度上同时全面压制血脂和代谢指标的情况，因此本文最终仍保留“总分层做主分析，子题项层做补充分析”的结构．

需要强调的是，问题一中的“筛选”对象仅限于血常规与活动量表变量，九种体质积分并不属于这一筛选集合，而是用于后续的体质贡献差异分析．因此，这里不把九类体质积分与筛选结果混在同一张表中．综合医学解释性、统计稳定性和后续建模可用性，本文将主分析中排序靠前的指标整理为三类建模关键变量，而活动量表总分则作为由 ADL 总分与 IADL 总分导出的派生变量，在问题二和问题三中继续使用：

1. 直接血脂指标：TG、TC、LDL-C、HDL-C，决定了当前是否已表现出明确的血脂异常；

2. 代谢协同指标：血尿酸、空腹血糖、BMI，反映代谢紊乱程度和生活方式风险；

3. 功能能力指标：ADL 总分、IADL 总分，反映身体耐受度和日常活动水平.

表 3 用于后续建模的关键指标及作用解释

类别	指标	主要作用
血脂类	TG、TC、LDL-C、HDL-C	直接决定当前是否存在血脂异常，是诊断型风险识别的核心变量
代谢类	血尿酸、空腹血糖、BMI	与脂质代谢紊乱、肥胖及胰岛素抵抗存在协同关系，适合用于早预警
功能类	ADL 总分、IADL 总分	作为主分析中的功能变量，刻画身体活动能力与耐受度，并对痰湿改善具有外在解释力
派生变量	活动量表总分	由 ADL 总分与 IADL 总分相加得到，主要用于问题二风险阈值与问题三强度约束

5.3 九种体质的风险贡献差异

本文采用“描述性风险提升度 + 模型化边际贡献”两层口径刻画九种体质的风险差异．首先，以主导体质标签为分组变量，定义第 k 类体质的风险提升度为

$$L_k = \frac{p_k}{p}, \tag{15}$$

其中 p_k 为主导体质标签为 k 的样本确诊率，p 为总体确诊率．若 $L_k > 1$，则说明该主导体质组的发病风险高于样本总体平均水平．该指标直观反映了不同主导体质组之间的组间差异，但它只使用了离散标签信息，无法反映同一样本同时具有多种体质偏颇的情形，也未控制年龄、性别、吸烟和饮酒等基础差异，因此更适合作为描述性统计而非最终的“贡献度”定义.

表 4 九种主导体质的确诊率与风险提升度

体质标签	样本量	确诊率	风险提升度
平和质	190	0.811	1.022
气虚质	90	0.800	1.009
阳虚质	75	0.827	1.042
阴虚质	80	0.787	0.993
痰湿质	292	0.781	0.985
湿热质	79	0.797	1.006
血瘀质	75	0.733	0.925
气郁质	66	0.788	0.994
特禀质	53	0.830	1.047

进一步地，记第 i 个样本第 k 类体质积分为 x_{ik}，其标准化变量定义为

$$z_{ik} = \frac{x_{ik} - \mu_k}{\sigma_k}, \tag{16}$$

其中 μ_k 与 σ_k 分别为第 k 类体质积分的样本均值和标准差．令 W_i 表示由年龄组、性别、吸烟和饮酒构成的基础控制变量向量，建立标准化逻辑回归模型

$$\Pr(Y_i = 1) = \frac{1}{1 + \exp\left[-\left(\beta_0 + \sum_{k=1}^{9} \beta_k z_{ik} + \gamma^\top W_i\right)\right]}, \tag{17}$$

其中 Y_i 表示样本 i 是否患高血脂．此处不再将 TC、TG、LDL-C、HDL-C 等直接诊断变量加入模型，是为了避免强同源血脂指标掩盖体质积分本身的边际作用．需要强调的是，逻辑回归中的系数 β_k 作用在对数几率上，而不是直接作用在发病概率上，因此不能把 β_k 直接解释为“概率增加了多少”．

设模型对样本 i 的预测概率为 $\hat{p}_i$，则第 k 类体质积分对该样本发病概率的局部影响为

$$\frac{\partial \Pr(Y_i = 1)}{\partial z_{ik}} = \hat{p}_i(1 - \hat{p}_i)\beta_k. \tag{18}$$

它表示：在其他变量保持不变时，第 k 类体质积分每增加 1 个标准差，样本 i 的高血脂预测概率会发生多大变化．由于不同样本的基线风险不同，这个变化量并不相同，因此需要对全体样本取平均．于是定义第 k 类体质的平均边际效应为

$$C_k = \frac{1}{n} \sum_{i=1}^{n} \hat{p}_i(1 - \hat{p}_i)\beta_k. \tag{19}$$

因此，C_k 可以理解为“第 k 类体质积分每增加 1 个标准差时，高血脂发病概率在全体样本上的平均变化量”．其符号表示影响方向：$C_k > 0$ 说明该体质积分升高会提高发病概率，$C_k < 0$ 说明其升高与发病概率下降相关；其绝对值越大，说明这种体质对概率的平均扰动越强．进一步定义贡献占比

$$G_k = \frac{|C_k|}{\sum_{j=1}^{9} |C_j|}, \tag{20}$$

则 G_k 可以理解为九种体质在模型意义下对总体风险影响强度的相对份额. 换言之，AME 先把逻辑回归系数从“对数几率尺度”转换为“概率尺度”，再通过归一化得到可直接比较的贡献占比.

样例数据表明，两层口径得到的结论并不完全一致. 若仅按修正后的主导体质标签分组，特禀质的风险提升度最高，为 1.047，血瘀质最低，为 0.925，说明九种主导体质在组间发病率上确有高低差异，但整体差距并不悬殊. 若转入模型化定义并控制基础信息，则气虚质的平均边际效应最大，贡献占比为 0.312；平和质次之，贡献占比为 0.229；湿热质和血瘀质的边际效应为负，说明在控制其他条件后，其积分升高与发病概率下降相关. 由此可见，主导体质标签的组间确诊率更接近“群体画像”，而标准化逻辑回归的平均边际效应更接近“体质积分本身的边际风险贡献”. 在后续风险预警中，本文以后者作为体质贡献差异的主定义，以前者作为辅助描述.

表 5 九种体质的模型化边际贡献（标准化逻辑回归 + AME）

体质类型	标准化系数	平均边际效应	贡献占比
气虚质	0.119	0.0193	0.312
平和质	0.087	0.0142	0.229
湿热质	-0.057	-0.0092	0.149
血瘀质	-0.057	-0.0092	0.149
特禀质	-0.023	-0.0037	0.060
阳虚质	0.019	0.0031	0.050
气郁质	0.018	0.0029	0.047
阴虚质	-0.001	-0.0002	0.004
痰湿质	0.000	0.0000	0.000

六、问题二：多维风险预警模型的构建

6.1 双层风险预警框架

本文将问题二拆分为两个层次：

1. 诊断型模型：输入全部体质、活动能力、血脂、代谢和基础信息，输出当前高血脂风险概率；

2. 早预警模型：去除 TC、TG、LDL-C、HDL-C，仅保留体质、活动、代谢及生活方式信息，用于识别尚未完全表现为直接血脂异常的高风险个体.

两类模型均采用随机森林分类器. 为降低极端值和偏态分布的影响，模型训练前先在训练集上完成连续变量的分位截尾与对数变换，并加入 non-HDL-C、活动受限计数以及体质强度特征等派生变量. 如图 2 所示，诊断型模型主要回答“当前是否已接近或达到高血脂状态”，因此保留 non-HDL-C、TG 和 LDL-C 等直接反映脂质负担的变量；早

预警模型则主要回答“在尚未出现明确血脂异常前，谁更可能向高风险演化”，因此删除直接血脂变量，只保留体质、活动、代谢与生活方式特征．这样拆分后，两类模型分别承担“当前识别”和“前瞻筛查”两种不同任务．

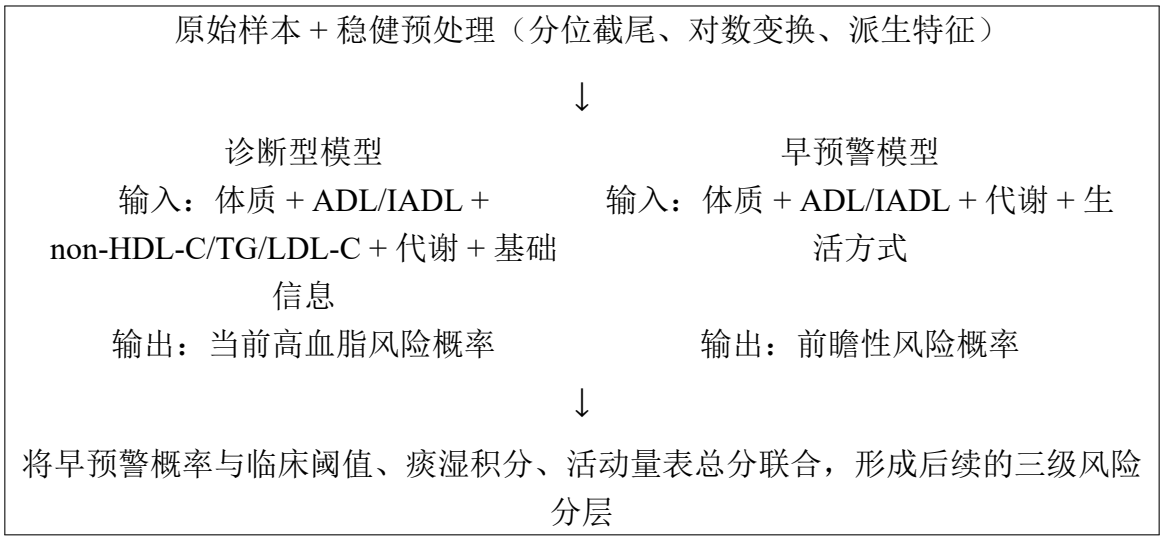

图 2 双层风险预警框架的输入–输出逻辑

样例数据上，诊断型模型的测试集 AUC 为 1.0000、准确率为 0.9840；早预警模型的测试集 AUC 为 0.8283、准确率为 0.7800．这说明：若用于“确诊辅助识别”，诊断型模型以 non-HDL-C、TG 和 LDL-C 为核心脂质结构变量，已能够几乎完全刻画当前高血脂状态；若用于“未病先防”与早期筛查，则血尿酸、血糖、BMI 以及体质积分仍能提供稳定信号．

表 6 双层风险模型的测试效果

模型	AUC	准确率	说明
诊断型模型	1.0000	0.9840	经稳健预处理后几乎可完全识别当前已接近或达到高血脂诊断标准的患者
早预警模型	0.8283	0.7800	排除直接血脂指标后仍保持稳定效果，更适合基层筛查与提前干预

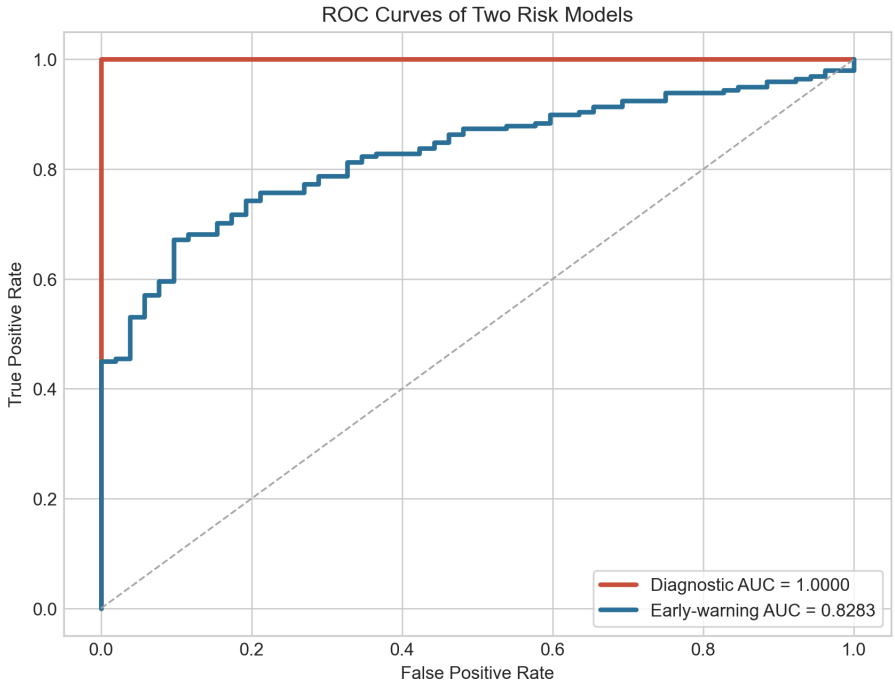

图 3 两类风险模型在测试集上的 ROC 曲线

图 3 给出了两类模型在测试集上的 ROC 曲线．可以看到，诊断型模型曲线几乎贴近左上角，说明其对“当前是否高血脂”的区分能力极强；早预警模型曲线虽然低于诊断型模型，但仍显著高于随机分类器，对基层筛查而言已经具有较好的可用性．

基于特征重要度，诊断型模型前五位特征依次为 non-HDL-C、log(1 + TG)、log(1 + 血尿酸)、截尾后的 LDL-C 和截尾后的空腹血糖；早预警模型前五位特征依次为 log(1 + 血尿酸)、截尾后的空腹血糖、截尾后的 BMI、血瘀质积分和阴虚质积分．换言之，诊断型模型主要抓取的是“当前脂质负担是否已经明显异常”，而早预警模型更关注“代谢紊乱 + 体质偏颇 + 活动受限”这一前期风险结构．

表 7 脚本输出得到的两类模型前五重要特征

模型	前五重要特征
诊断型模型	non-HDL-C、log(1 + TG)、log(1 + 血尿酸)、截尾后的 LDL-C、截尾后的空腹血糖
早预警模型	log(1 + 血尿酸)、截尾后的空腹血糖、截尾后的 BMI、血瘀质积分、阴虚质积分

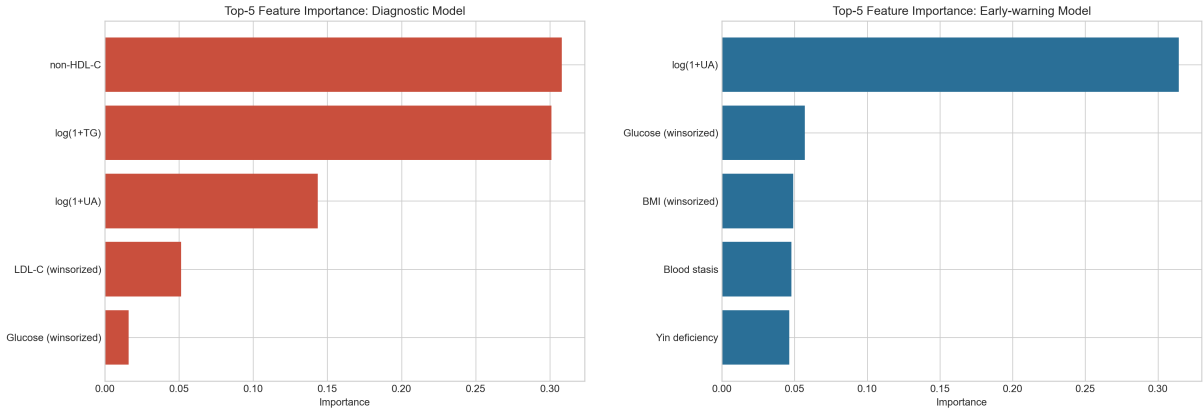

图 4 诊断型模型与早预警模型的前五重要特征

图 4 左右分别给出了诊断型模型和早预警模型的前五重要特征．两张特征重要度图进一步说明，两类模型依赖的信号并不相同：诊断型模型主要由 non-HDL-C、$\log(1+\mathrm{TG})$ 和 LDL-C 驱动，反映的是当前脂质负担；早预警模型则更多依赖血尿酸、血糖、BMI 以及血瘀质、阴虚质等体质信号，反映的是风险形成前期的代谢和体质结构．

6.2 三级风险阈值设计

记样本的痰湿积分为 P，活动量表总分为 Q，血脂异常个数为 A，早预警模型输出概率为 $\hat{p}$．综合题目给出的临床正常区间与样例数据中学习到的风险规律，定义三级风险划分规则为

$$R = \begin{cases} \text{高风险}, & (A \geq 1 \wedge P \geq 60) \ \vee \ (A = 0 \wedge P \geq 80 \wedge Q < 40) \ \vee \ \hat{p} \geq 0.80, \\ \text{中风险}, & A \geq 1 \ \vee \ P \geq 60 \ \vee \ (\hat{p} \geq 0.45 \wedge Q < 60), \\ \text{低风险}, & \text{其余情形}. \end{cases} \tag{21}$$

其中，A 的计算依据为 TC、TG、LDL-C 是否超过题目给定上限，以及 HDL-C 是否低于题目给定下限．该规则兼顾了三方面信息：第一，临床血脂异常是最直接的危险信号；第二，痰湿积分高而活动能力低的人群，即便暂未表现出明显血脂异常，也可能处于早期高风险状态；第三，模型输出概率用来兜底吸收多变量之间的非线性交互关系．

表 8 三级风险分层阈值规则

风险等级	划分依据
低风险	血脂指标全部正常，痰湿积分 < 60，活动量表总分较高，且模型输出概率较低
中风险	至少存在一项血脂异常，或痰湿积分 ≥ 60，或模型概率达到中等水平且活动能力不足
高风险	满足“血脂异常 + 痰湿积分高”、“血脂正常但痰湿积分极高且活动能力很低”或模型概率 ≥ 0.80 的任一情形

按式 (21) 对样例数据分层后，低、中、高风险样本数分别为 59、292、649；在修正后主导体质标签为痰湿质的 292 例样本中，高风险人数为 207，占比达到 70.89%.

6.3 高风险核心特征组合识别

对高风险样本进行特征组合统计后可见，出现频次最高的模式主要包括：

1. 血脂异常 + 尿酸偏高；
2. 血脂异常 + 吸烟史/饮酒史；
3. 血脂异常 + 尿酸偏高 + 吸烟史 + 饮酒史；
4. 痰湿积分高 + 低活动量 + 血脂异常；
5. 血脂异常 + BMI 偏高 + 尿酸偏高.

其中，“血脂异常 + 尿酸偏高”是最高频的高风险组合；若再叠加吸烟、饮酒、BMI 偏高或活动能力低，则风险进一步放大. 这一结果说明高血脂并非孤立的单指标异常，而是代谢异常、生活方式风险与体质偏颇共同驱动的结果. 对痰湿体质人群而言，痰湿积分本身提供了中医维度的先验风险，而活动能力下降则意味着代谢调节能力和后续干预耐受度均相对较差，因此应优先纳入高风险监测名单.

七、问题三：痰湿体质患者的六个月干预优化

7.1 决策变量与约束条件

对主导体质标签为 5 的患者，设活动干预强度为 u，每周训练频次为 f. 根据题目要求：

1. u 受年龄组和活动量表总分的双重约束；
2. $f \in \{1, 2, \ldots, 10\}$；
3. 六个月总成本不超过 2000 元；
4. 痰湿积分目标设为六个月后至少下降 10%，即 $s_6 \le 0.9 s_0$.

活动干预的月度降分比例定义为

$$r(u, f) = \begin{cases} 0, & f < 5, \\ 0.03(u-1) + 0.01(f-5), & f \ge 5. \end{cases} \tag{22}$$

于是痰湿积分的月度递推关系为

$$s_{m+1} = s_m\big(1 - r(u, f)\big), \qquad m = 0, 1, \ldots, 5. \tag{23}$$

中医调理等级根据当月积分自动匹配：0–58 分为一级、59–61 分为二级、≥ 62 分为三级．记对应月成本函数为 $c_{\text{tcm}}(s_m)$；活动训练的单次成本为 c_u，则六个月总成本为

$$C = \sum_{m=1}^{6} \left[c_{\text{tcm}}(s_{m-1}) + 4f\, c_u \right]. \tag{24}$$

据此建立如下优化模型：

$$\min_{u,f} \; C \tag{25}$$

满足

$$s_6 \le 0.9 s_0, \qquad C \le 2000, \qquad u \in \mathcal{I}(\text{年龄组}, Q), \qquad f \in \{1, \ldots, 10\}, \tag{26}$$

其中 $\mathcal{I}(\text{年龄组}, Q)$ 表示由年龄组和活动量表总分共同决定的允许强度集合．

7.2 样本 1、2、3 的最优方案

采用枚举法遍历所有可行的 (u, f) 组合，并按“优先满足目标、再最小化成本、最后最小化期末痰湿积分”的原则排序，可得样本 1, 2, 3 的最优方案如表 9 所示．

表 9 样本 1、2、3 的六个月最优干预方案

样本 ID	初始痰湿积分	目标上限	活动总分	最优强度 u	每周频次 f	总成本 / 期末积分
1	64.0	57.6	38	1	10	1050 元 / 47.05
2	58.0	52.2	40	1	7	684 元 / 51.38
3	59.0	53.1	63	1	7	734 元 / 52.27

从结果可以看出，样本 1 因活动总分仅为 38，即使年龄允许更高强度，也只能采用一级强度，因此只能通过提高训练频次来弥补强度不足；样本 2 和样本 3 的初始痰湿积分分别位于一级和二级调理边界附近，采用“一级强度 + 每周 7 次”的方案即可在预算内完成目标．尤其是样本 3，虽然活动总分较高、理论上可选更高强度，但提高强度会显著增加活动成本，而对达到 10% 的降分目标并无必要，因此低强度中高频次反而更经济．

7.3 患者特征与最优方案的匹配规律

综合所有可行方案的搜索结果，可以总结出如下匹配规律：

1. 若年龄较大或活动量表总分偏低，则强度选择空间被压缩，此时应优先通过增加频次改善干预效果；
2. 若初始痰湿积分处于 59–62 分附近，则前两个月的积分下降会降低中医调理等级，从而减少后续调理成本，因此适度提高前期训练频次往往更划算；

3. 若患者活动能力较高但目标降幅不大，盲目追求高强度并不一定优于低强度中等频次，因为训练成本上涨快于收益；

4. 预算约束下，“低强度 + 合理频次 + 动态降低调理等级”是最稳健的经济策略.

八、模型检验与结果讨论

本文模型的检验主要从三个角度展开.

1. **结果一致性检验**：诊断型模型的重要特征集中在 TG、non-HDL-C、LDL-C 及少量代谢变量，与高血脂临床诊断中“甘油三酯异常 + 非 HDL 胆固醇负担 + LDL 负担”的识别逻辑一致；早预警模型的重要特征集中在血尿酸、血糖、BMI 和体质、活动变量，与慢病早筛的医学常识相符.

2. **阈值可解释性检验**：三级风险阈值同时引用了临床正常值区间、痰湿积分与活动能力规则，不依赖黑盒模型单独输出，便于基层使用者理解与执行.

3. **干预可行性检验**：样本 $1, 2, 3$ 的最优方案均满足年龄约束、活动能力约束和预算约束，且最终痰湿积分均达到既定目标，说明优化模型具有实际可操作性.

需要指出的是，样例数据中确诊样本占比达到 79.3%，类别分布并不均衡，这会抬高部分单体质组的表观确诊率. 因此，若后续补充了更多社区筛查数据，应优先采用分层抽样、代价敏感学习或重采样手段增强模型稳健性.

九、模型评价与改进方向

9.1 模型优点

1. 将“诊断识别”和“未病预警”分开建模，避免直接血脂指标掩盖其他变量的预警价值；

2. 风险等级规则可解释性强，便于在社区卫生服务场景中落地；

3. 干预模型直接嵌入了题目给定的强度、频次、年龄与预算约束，输出方案具有较强操作性；

4. 建模流程统一，问题一的筛选结果可自然过渡到问题二和问题三.

9.2 模型不足

1. 中医调理等级只给出了成本标准，未给出独立的降分函数，因此本文将其作为基础成本而非单独的收益项；

2. 活动干预效果采用固定月度下降比例，尚未考虑患者依从性波动和边际收益递减；

3. 样例数据存在类别不平衡现象，且不同体质之间可能存在多重共线性，使单体质贡献的解释受到一定干扰.

9.3 改进方向

1. 若能补充随访数据，可将问题三拓展为动态规划或模型预测控制问题；
2. 若能获得更细致的中医调理效果数据，可把饮食调理、穴位按摩、八段锦和代茶饮拆分为独立决策变量；
3. 若后续加入更多地区、更多时间段样本，可建立跨区域迁移学习模型，提高外部泛化能力.

参考文献

[1] 2026 年第十六届 MathorCup 数学应用挑战赛 C 题：中老年人群高血脂症的风险预警及干预方案优化.

[2] Breiman L. Random Forests[J]. Machine Learning, 2001, 45(1): 5-32.

[3] Hastie T, Tibshirani R, Friedman J. The Elements of Statistical Learning[M]. New York: Springer, 2009.

[4] Bishop C M. Pattern Recognition and Machine Learning[M]. New York: Springer, 2006.

附　录

附录 1：算法实现说明

本文当前用于结果整理与论文回填的程序化实现文件位于赛题/C 题目录下．其文件名为 `c_problem_starter.py`，主要完成以下功能：

1. 使用 `pandas.read_excel()` 直接读取附件中的 `xlsx` 文件，并将中文列名映射为便于建模的英文列名；
2. 计算问题一中的综合筛选得分、体质风险差异；
3. 训练问题二中的诊断型模型与早预警模型，并输出三级风险分层结果；
4. 枚举问题三中的强度与频次组合，输出指定患者的最优方案．

该脚本同时也是 notebook 逐段拆解版本对应的唯一主脚本，后续结果复现实验均以它为准．

附录 2：问题三核心求解伪代码

```
for each patient in phlegm_damp_group:
    feasible_plans = []
    for intensity in allowed_intensities(age_group, activity_score):
        for freq in range(1, 11):
            score = baseline_phlegm_score
            cost = 0
            for month in range(1, 7):
                level = tcm_level(score)
                cost += tcm_monthly_cost[level]
                cost += 4 * freq * unit_training_cost[intensity]
                score = score * (1 - activity_drop_ratio(intensity, freq))
            feasible_plans.append((intensity, freq, score, cost))
    choose plan with:
        1) target satisfied first
        2) lower total cost
        3) lower final score
```